

LAPORAN TUGAS BESAR

**Prediksi Harga Komoditas Pangan Bulanan Menggunakan Pendekatan
Machine Learning Regression Berbasis Fitur Temporal**

**Diajukan untuk Memenuhi Kelulusan Mata Kuliah Data *Mining*
pada Program Studi DIV Teknik Informatika**



DISUSUN OLEH:

Ode Andi Alamsyah	714230032
Nesya Salma Ramadhani	714230028
Indah Diva Gracia	714230039
Rendy Kamaluddin	714230030

**PROGRAM STUDI D-IV TEKNIKINFORMATIKA
SCHOOL OF INFORMATION TECHNOLOGY
UNIVERSITAS LOGISTIK & BISNIS INTERNASIONAL
BANDUNG**

Kata Pengantar

Puji syukur ke hadirat Tuhan Yang Maha Esa atas segala rahmat, karunia, dan penyertaan-Nya sehingga laporan penelitian yang berjudul "Prediksi Harga Komoditas Pangan Bulanan Menggunakan *Algoritma Linear Regression* dan *Random Forest Regression*" dapat diselesaikan dengan baik.

Laporan ini disusun sebagai salah satu bentuk pemenuhan tugas pada mata kuliah Data Mining. Penelitian ini bertujuan untuk membangun model prediksi harga komoditas pangan bulanan menggunakan algoritma *Linear Regression* dan *Random Forest Regression*, menganalisis pengaruh penerapan *feature engineering* terhadap kemampuan model dalam menangkap pola data, serta mengevaluasi pengaruh optimasi *hyperparameter* menggunakan metode *Grid Search*, *Random Search*, dan *Bayesian Optimization* terhadap performa model prediksi.

Dalam penyusunan laporan ini, berbagai tahapan telah dilakukan, mulai dari pengumpulan dan pengolahan data, proses *preprocessing*, penerapan *feature engineering*, pembangunan model prediksi, optimasi *hyperparameter*, hingga evaluasi model menggunakan metrik *Mean Absolute Error (MAE)*, *Root Mean Squared Error (RMSE)*, *Mean Absolute Percentage Error (MAPE)*, dan *R² Score*. Seluruh tahapan tersebut dilakukan untuk menghasilkan model prediksi yang mampu memberikan hasil yang akurat dan dapat digunakan sebagai dasar dalam menganalisis pergerakan harga komoditas pangan.

Penyusun menyadari bahwa laporan ini masih memiliki keterbatasan dan belum sepenuhnya sempurna. Oleh karena itu, kritik dan saran yang bersifat membangun sangat diharapkan guna menyempurnakan penelitian maupun penyusunan laporan di masa mendatang.

Akhir kata, semoga laporan ini dapat memberikan manfaat, menambah wawasan, serta menjadi referensi bagi pembaca dalam memahami penerapan metode Data Mining, khususnya algoritma *Linear Regression* dan *Random Forest Regression* untuk prediksi harga komoditas pangan.

Bandung, Juni 2026

Penulis

Daftar Isi

Kata Pengantar	2
Daftar Isi	3
Daftar Gambar	5
Daftar Tabel	6
BAB I Pendahuluan	7
1.1 Latar Belakang	7
1.2 Rumusan Masalah	8
1.3 Tujuan Penelitian	8
1.4 Manfaat Penelitian	8
BAB II Tinjauan Pustaka	10
2.1 Tinjauan Studi	10
2.2 <i>State Of The Art</i>	12
2.3 GAP Penelitian	12
2.4 Landasan Teori	17
BAB III Metodologi Penelitian	21
3.1 Metode Penelitian	21
3.2 Tahapan Penelitian	21
3.2.1 Pengumpulan Data	22
3.2.2 Analisis Data	22
3.2.3 <i>Preprocessing</i> Data	23
3.2.4 <i>Feature engineering</i>	23
3.2.5 Pembagian <i>Dataset</i>	24
3.2.6 Pembagian Model	24
3.2.7 Optimasi <i>Hyperparameter</i>	25

3.2.8	<i>Pseudocode</i> Proses Pelatihan dan Optimasi Model	25
3.2.9	Evaluasi model.....	30
3.2.9	Analisis hasil.....	31
BAB IV Hasil dan Pembahasan		33
4.1	Deskripsi <i>Dataset</i>	33
4.2	Eksplorasi Data (<i>EDA</i>).....	36
4.3	<i>Preprocessing</i>	44
4.4	Pembuatan Model	52
a.	<i>Grid Search</i>	53
b.	<i>Random Search</i>	53
c.	<i>Bayesian Optimization</i>	53
4.5	Hasil Prediksi	55
4.6	Evaluasi Model	56
BAB V Penutup		59
5.1	Kesimpulan	59
5.2	Saran	60
Daftar Pustaka.....		61

Daftar Gambar

Gambar 2. 1 Tingkat Fluktuasi Harga Pangan Tahunan Nasional (2021–2026). Sumber: Perkembangan Harga Pangan, Badan Pangan Nasional (2026)	10
Gambar 2. 2 Tren dan Forecasting Inflasi Umum MtM (2020–2027). Sumber: Inflasi Bahan Makanan, Badan Pangan Nasional (2026).....	11
Gambar 4. 1 Data Awal <i>Dataset</i>	34
Gambar 4. 2 Struktur <i>Dataset</i>	35
Gambar 4. 3 Statistik <i>Deskriptif Dataset</i>	35
Gambar 4. 4 Jumlah Data per Komoditas	37
Gambar 4. 5 Jumlah Data per Tahun	38
Gambar 4. 6 Jumlah Data per Bulan	39
Gambar 4. 7 Distribusi Harga Komoditas.....	39
Gambar 4. 8 <i>Boxplot</i> Harga Komoditas	40
Gambar 4. 9 Rata-rata Harga per Komoditas.....	41
Gambar 4. 10 Tren Rata-rata Harga per Tahun	42
Gambar 4. 11 Tren Harga Beberapa Komoditas.....	43
Gambar 4. 12 <i>Heatmap</i> Rata-rata Harga per Tahun dan Bulan	44
Gambar 4. 13 Hasil <i>Cleaning</i> Nama Kolom dan Data Teks	45
Gambar 4. 14 Hasil <i>Cleaning</i> Kolom Harga	46
Gambar 4. 15 Penanganan <i>Missing Value</i>	46
Gambar 4. 16 Statistik Harga Setelah <i>Cleaning</i>	47
Gambar 4. 17 Hasil <i>Feature Engineering</i>	50
Gambar 4. 18 Perbandingan Nilai Aktual dan Hasil Prediksi Model Terbaik.....	56

Daftar Tabel

Tabel 2. 1 Matriks Perbandingan Penelitian Terdahulu dan GAP Penelitian	13
Tabel 3. 1 Pseudocode	26
Tabel 3. 2 Interpretasi MAPE	31
Tabel 4. 1 Informasi Dataset	33
Tabel 4. 2 Tipe Data Dataset.....	34
Tabel 4. 3 Encoding Bulan.....	47
Tabel 4. 4 Fitur Hasil Feature Engineering.....	49
Tabel 4. 5 Pembagian Data Latih dan Data Uji	51
Tabel 4. 6 Model yang Digunakan.....	54
Tabel 4. 7 Hasil Prediksi Setiap Model.....	55
Tabel 4. 8 Hasil Prediksi Setiap Model.....	57

BAB I

Pendahuluan

1.1 Latar Belakang

Perkembangan teknologi informasi telah mendorong pemanfaatan data dalam berbagai bidang, termasuk sektor pangan. Data harga komoditas pangan merupakan salah satu informasi penting yang digunakan oleh pemerintah, pelaku usaha, maupun masyarakat dalam mengambil keputusan ekonomi [1]. Perubahan harga komoditas pangan dipengaruhi oleh berbagai faktor, seperti musim, kondisi cuaca, distribusi, permintaan pasar, inflasi, hingga kebijakan pemerintah [2]. Akibatnya, harga komoditas sering mengalami fluktuasi dari waktu ke waktu.

Fluktuasi harga tersebut dapat menyebabkan ketidakpastian bagi masyarakat maupun pelaku usaha. Oleh karena itu, diperlukan suatu metode yang mampu memperkirakan atau memprediksi harga komoditas pada periode berikutnya sehingga dapat digunakan sebagai dasar dalam pengambilan keputusan.

Salah satu pendekatan yang dapat digunakan adalah *Data Mining*, yaitu proses menggali informasi atau pola tersembunyi dari sekumpulan data [3]. Dalam penelitian ini digunakan teknik Regresi, karena variabel yang diprediksi berupa nilai numerik, yaitu harga komoditas pangan. Algoritma regresi mampu mempelajari hubungan antara variabel waktu dengan harga sehingga menghasilkan model prediksi yang dapat digunakan untuk memperkirakan harga pada periode mendatang.

Dataset yang digunakan merupakan data harga berbagai komoditas pangan bulanan yang terdiri dari 1.227 data dengan atribut komoditas, tahun, bulan, dan harga. Sebelum dilakukan pemodelan, data akan melalui tahap *preprocessing* agar kualitas data menjadi lebih baik. Selanjutnya dilakukan pelatihan model regresi dan evaluasi menggunakan metrik seperti *Mean Absolute Error (MAE)*, *Root Mean Squared Error (RMSE)*, dan koefisien determinasi (R^2) untuk mengetahui tingkat akurasi model.

Melalui penelitian ini diharapkan diperoleh model prediksi yang mampu memberikan estimasi harga komoditas pangan secara akurat sehingga dapat menjadi informasi pendukung bagi pemerintah, pelaku usaha, maupun masyarakat dalam merencanakan kebijakan, strategi bisnis, maupun pengelolaan kebutuhan pangan.

1.2 Rumusan Masalah

1. Bagaimana membangun model prediksi harga komoditas pangan bulanan menggunakan algoritma *Linear Regression* dan *Random Forest Regression* berdasarkan data historis harga?
2. Bagaimana pengaruh penerapan *feature engineering*, seperti *lag features*, *moving average*, perubahan harga, dan persentase perubahan harga, terhadap kemampuan model dalam menangkap pola temporal harga komoditas pangan?
3. Bagaimana pengaruh metode *Grid Search*, *Random Search*, dan *Bayesian Optimization* dalam mengoptimalkan *hyperparameter* model regresi sehingga menghasilkan performa prediksi yang lebih baik?
4. Model regresi manakah yang memberikan performa terbaik dalam memprediksi harga komoditas pangan bulanan berdasarkan nilai *MAE*, *RMSE*, *MAPE*, dan *R² Score*?

1.3 Tujuan Penelitian

1. Mengembangkan model prediksi harga komoditas pangan bulanan menggunakan *algoritma Linear Regression* dan *Random Forest Regression*.
2. Menerapkan *feature engineering* berbasis data historis, meliputi *lag features*, *moving average*, perubahan harga, dan persentase perubahan harga untuk meningkatkan representasi pola temporal.
3. Mengoptimalkan *hyperparameter* model menggunakan *Grid Search*, *Random Search*, dan *Bayesian Optimization*.
4. Membandingkan performa kedua model regresi berdasarkan metrik evaluasi *MAE*, *RMSE*, *MAPE*, dan *R² Score* untuk menentukan model yang paling akurat.

1.4 Manfaat Penelitian

Penelitian ini diharapkan memberikan manfaat sebagai berikut.

1. Manfaat Teoritis

1. Menambah referensi mengenai penerapan metode *Data Mining* dalam prediksi harga komoditas pangan.
2. Memberikan kontribusi terhadap pengembangan penelitian mengenai *algoritma Linear Regression* dan *Random Forest Regression* untuk kasus prediksi harga.
3. Menjadi acuan bagi penelitian selanjutnya yang berkaitan dengan analisis data ekonomi dan peramalan harga komoditas.
4. Memperkaya kajian ilmiah mengenai penerapan *feature engineering* dan *optimasi hyperparameter* dalam meningkatkan performa model prediksi.

2. Manfaat Praktis

1. Bagi Pemerintah: Membantu dalam mendukung penyusunan kebijakan pengendalian dan stabilisasi harga komoditas pangan.
2. Bagi Pelaku Usaha: Membantu dalam menentukan strategi pembelian, penyimpanan stok, dan penjualan komoditas berdasarkan hasil prediksi harga.
3. Bagi Masyarakat: Memberikan informasi prediksi harga yang dapat dijadikan pertimbangan dalam merencanakan kebutuhan dan pengeluaran rumah tangga.
4. Bagi Akademisi: Menjadi contoh implementasi proses data *mining* yang meliputi *preprocessing*, *feature engineering*, pemodelan, optimasi *hyperparameter*, dan evaluasi model regresi.

BAB II

Tinjauan Pustaka

2.1 Tinjauan Studi

Ketidakstabilan harga komoditas pangan merupakan salah satu tantangan ekonomi makro yang krusial di Indonesia [4]. Komoditas pangan seperti beras, cabai, bawang, dan daging memiliki tingkat volatilitas yang tinggi karena sangat dipengaruhi oleh faktor musiman, pola cuaca ekstrem, kendala logistik distribusi antar-wilayah, serta fluktuasi permintaan pasar yang tidak menentu. Perubahan harga pangan yang tidak terduga ini memberikan dampak langsung berupa guncangan inflasi nasional serta penurunan daya beli masyarakat luas [4], [5].

Untuk memberikan gambaran empiris mengenai kondisi volatilitas pangan di Indonesia, Badan Pangan Nasional (BPN) mencatat pergerakan tingkat fluktuasi harga tahunan secara agregat dari periode tahun 2021 hingga tahun 2026 yang disajikan pada gambar 2.1.

TINGKAT FLUKTUASI HARGA


Level har... ▲ Tahunan ▼	Tingkat Konsumen		Tingkat Produsen	
	Harga	Tingkat Fluktuasi	Harga	Tingkat Fluktuasi
2026	Rp40,861	93	Rp25,264	63
2025	Rp39,415	92	Rp25,227	62
2024	Rp31,404	88	Rp22,875	65
2023	Rp31,120	91	Rp22,589	69
2022	Rp32,571	97	Rp22,846	70
2021	Rp31,583	97	Rp20,836	75

Gambar 2. 1 Tingkat Fluktuasi Harga Pangan Tahunan Nasional (2021–2026). Sumber: Perkembangan Harga Pangan, Badan Pangan Nasional (2026)

Berdasarkan data pada Gambar 2.1, terlihat adanya tren kenaikan harga rata-rata komoditas pangan yang signifikan, khususnya di tingkat konsumen. Pada tahun 2021, rata-rata harga berada di angka Rp31.583 dengan tingkat fluktuasi sebesar 97. Meskipun sempat mengalami pola pergerakan yang dinamis pada tahun 2022 hingga 2024, lonjakan harga yang sangat tajam terjadi pada tahun 2025 di mana harga rata-rata melesat hingga Rp39.415 dengan tingkat fluktuasi 92, dan terus merangkak naik hingga mencapai Rp40.861 pada tahun 2026 dengan tingkat fluktuasi sebesar 93. Fenomena serupa juga terjadi di tingkat produsen, di mana harga bergerak dari Rp20.836 (2021) menjadi Rp25.264 (2026). Tingginya angka indeks fluktuasi yang konsisten berada di atas nilai 60 (tingkat produsen) dan bahkan mencapai angka 90-an

(tingkat konsumen) mengonfirmasi bahwa ketidakpastian harga pangan di pasar nasional masih sangat tinggi.

Dampak langsung dari fluktuasi harga pangan ini tercermin secara berkala pada angka inflasi bulanan (Month-to-Month / MtM). Pola historis inflasi umum dan peramalannya secara kronologis digambarkan pada Gambar 2.2.



Gambar 2. 2 Tren dan Forecasting Inflasi Umum MtM (2020–2027). Sumber: Inflasi Bahan Makanan, Badan Pangan Nasional (2026)

Gambar 2.2 menunjukkan visualisasi runtun waktu (*time series*) fluktuasi inflasi bulanan dari Januari 2020 hingga pertengahan tahun 2026, disertai dengan area proyeksi (*forecasting shadow*) hingga tahun 2027. Terlihat jelas bahwa titik-titik aktual (*actual points*) inflasi kerap mengalami lonjakan ekstrem (menembus angka 0.5 bahkan mendekati 1.5 pada awal 2025) yang kemudian diikuti oleh penurunan tajam hingga ke zona deflasi (di bawah 0.0). Pola pergerakan yang acak, naik-turun secara radikal, serta memiliki ketergantungan temporal yang kuat pada periode-periode sebelumnya (*lagging effect*) ini membuktikan bahwa pendekatan pemodelan linier sederhana akan kesulitan dalam menangkap perilaku data secara utuh.

Kombinasi data empiris dari gambar 2.1 dan gambar 2.2 inilah yang menjadi landasan utama mengapa penelitian ini dilakukan. Melalui pembangunan model prediksi berbasis *machine learning regression* yang diperkaya oleh fitur temporal (*lag features* dan *moving average*), diharapkan model mampu

mereduksi *noise* dari fluktuasi radikal tersebut. Dengan demikian, akurasi prediksi yang dihasilkan dapat menjadi instrumen pendukung keputusan (*decision support system*) yang valid bagi pemerintah maupun pelaku usaha dalam mengantisipasi risiko lonjakan harga komoditas pangan di masa mendatang.

2.2 State Of The Art

Dalam beberapa tahun terakhir, penelitian mengenai peramalan dan prediksi harga komoditas pangan telah bergeser dari metode statistik konvensional seperti ARIMA atau Exponential Smoothing menuju pemanfaatan algoritma berbasis Machine Learning Regression. Metode statistik klasik sering kali gagal dalam menangkap pola data yang memiliki fluktuasi nonlinier dan interaksi fitur yang kompleks [6], [7], [8].

State of the art (kebaruan/perkembangan terkini) dari pemodelan prediksi komoditas pangan berfokus pada dua aspek utama: penerapan ekspansi Feature Engineering berbasis temporal dan teknik optimasi otomatis terhadap parameter model (Hyperparameter Tuning) [9]. Penelitian terbaru menunjukkan bahwa performa model regresi akan meningkat secara signifikan ketika data deret waktu (time-series) [6], [10], [11], [12], tidak hanya menggunakan fitur mentah, melainkan ditransformasikan ke dalam fitur lag harga, Moving Average (MA), selisih harga (Price Difference), serta persentase perubahan harga bulanan .

Dalam hubungannya dengan topik penelitian ini, kami membandingkan model regresi linier klasik (Linear Regression) sebagai baseline dengan algoritma berbasis ensemble learning yaitu Random Forest Regression. Berbeda dengan model linier yang mengasumsikan hubungan konstan, Random Forest mampu memetakan struktur data nonlinier pada volatilitas pangan melalui kumpulan pohon keputusan (decision trees). Lebih lanjut, penelitian ini membawa state of the art pemodelan ke tahap optimasi lanjut dengan membandingkan tiga metode pencarian parameter sekaligus, yaitu Grid Search, Random Search, dan Bayesian Optimization, untuk menemukan konfigurasi pohon keputusan yang paling akurat dalam menekan nilai error (MAE, RMSE, MAPE) pada 47 komoditas pangan nasional.

2.3 GAP Penelitian

Penelitian mengenai prediksi harga komoditas pangan terus mengalami perkembangan, baik dari segi kompleksitas algoritma maupun cakupan fitur yang digunakan. Namun demikian, terdapat celah (*gap*) yang signifikan antara penelitian-penelitian terdahulu dengan kondisi riil kebutuhan analisis saat ini. Sebagian besar penelitian terdahulu berfokus pada pendekatan spasial regional dengan jumlah komoditas yang terbatas, memiliki kerentanan *false error* pada arsitektur *deep learning* jika dihadapkan pada karakteristik tren data tertentu, bersifat *myopic* pada satu jenis komoditas lokal, mengabaikan efek dari jeda

waktu akuisisi data (*data time lag*), memerlukan arsitektur hibrida kombinasi yang sangat kompleks dan intensif komputasi, serta hanya memetakan indeks harga dalam bentuk makro agregat global tunggal yang belum mencakup eskalasi volatilitas harga domestik terbaru.

Berikut adalah tabel matriks penelitian terdahulu yang memetakan posisi dan perbandingan literatur yang sudah ada:

Tabel 2. 1 Matriks Perbandingan Penelitian Terdahulu dan GAP Penelitian

No	Peneliti dan Tahun	Metode yang Digunakan	Komoditas/Objek	Fitur yang Digunakan	Batasan/GAP
1	Guo, dkk. (2022) [13]	Model Kombinasi Hibrida AttLSTM-ARIMA-BP di bawah algoritma asosiasi Apriori	Harga Jagung di Provinsi Sichuan, China (511 observasi mingguan)	Atribut spasial-temporal harga spot domestik dan bursa berjangka (<i>futures</i>) komoditas terkait (kedelai, beras, gandum)	Arsitektur hibrida sangat kompleks karena menggabungkan 4 model sekaligus (Apriori, Attention, LSTM, ARIMA, BP). Hal ini memicu beban komputasi tinggi dan rumitnya pencarian <i>hyperparameter</i> yang menghambat efisiensi model untuk diimplementasikan pada puluhan komoditas secara dinamis, serta sangat bergantung pada ketersediaan data harga berjangka.
2	Ulussever, dkk. (2023) [12]	Komparasi Machine Learning (MLP, MARS, SVM, RF, XGB, kNN) vs. Ekonometrika Runtun Waktu	Indeks Harga Pangan Dunia Agregat Global (<i>World Food Price Index</i> meliputi sereal, minyak, gula, daging, susu)	8 Eksogenus Global (Harga minyak mentah Brent, indeks bahan baku, indeks pupuk, logam/mineral, UNCERT, VIX, suhu Bumi, dan Lag-1 harga)	Pemodelan bersifat makro agregat global tunggal dari sisi penawaran (<i>supply-side</i>), sehingga tidak mampu mengidentifikasi fluktuasi mikro lokal domestik serta inter-

					komoditas pangan yang spesifik secara individual di tingkat konsumen retail.
3	Muchtar & Afiyati (2024) [14]	Komparasi algoritma Linear Regression dan Random Forest Regression	Komoditas Beras Premium di Provinsi Jawa Barat (6.096 records)	Atribut internal pasokan (Luas panen padi, harga tingkat petani, penggilingan, GKP, GKG)	Penelitian bersifat <i>single-commodity</i> (hanya beras premium) dan terbatas pada cakupan satu wilayah provinsi; pembangunan algoritma <i>Random Forest</i> belum dilengkapi oleh optimasi <i>hyperparameter tuning</i> tingkat lanjut.
4	Suaza-Medina, dkk. (2023) [10]	Komparasi 11 Algoritma (Statistical, Machine Learning, & Deep Learning	Komoditas Daging Babi di Pasar Regional Lleida, Spanyol (322 minggu)	Runtun waktu harga mingguan lokal terintegrasi dengan data publik dan data langganan berbayar	Berfokus pada analisis dampak jeda waktu publikasi (<i>data time lag</i>), namun pemodelan menunjukkan bahwa penambahan sekuens data historis jangka panjang justru memicu <i>noise</i> yang memperburuk hasil peramalan pada model multivariat.
5	Sifriyani, dkk. (2025) [15]	Geographically and Temporally Weighted Spline Regression (GTWSR)	8 Komoditas Pangan Strategis di 34 Provinsi di Indonesia	Koordinat spasial (geografis provinsi) dan indeks waktu bulanan	Cakupan temporal terbatas hanya sampai Agustus 2024 sehingga belum menangkap fluktuasi makroekonomi pasca tahun tersebut; objek komoditas terbatas

					pada 8 jenis pangan strategis utama.
6	Sediyono, dkk. (2025) [16]	Deep Transformer & Attention-Boosted LSTM Variational Autoencoder (LSTM-VAE)	Komoditas Beras, Cabai Merah, dan Bawang Merah harian di wilayah NTT (2020–Juni 2024)	Runtun waktu harga harian tunggal (<i>univariate daily price sequence</i>)	Arsitektur <i>deep learning</i> yang kompleks berisiko memunculkan anomali semu (<i>false positives</i>) pada komoditas pangan berkarakteristik stabil (seperti beras). Model menganggap ketiadaan fluktuasi harian sebagai anomali stasis, serta data terhenti di pertengahan 2024.
7	Odion, dkk. (2025) [17]	Online Machine Learning Pipeline dengan algoritma Random Forest Regression	5 Komoditas Pangan Hortikultura di 36 Negara Bagian Nigeria (2017–Maret 2023)	Fitur internal (Lag harga 1 & 5 bulan, Roll-up harga) serta Exogenous (CPI, Kurs USD, Harga Minyak)	Volume data latih sangat terbatas (hanya 75 data poin per kombinasi) sehingga membatasi pemanfaatan model <i>deep networks</i> ; akurasi model menurun dan tidak stabil ketika memprediksi area wilayah konsumsi perkotaan yang memiliki tingkat volatilitas ekstrem.

Melalui pemetaan matriks penelitian terdahulu pada Tabel 2.1, terlihat jelas adanya ruang kosong (*research gap*) yang mendasari pentingnya perancangan alur pemodelan dalam penelitian ini guna menjawab keterbatasan literatur melalui empat sasaran strategis. Untuk menjawab celah pertama mengenai ketidakseimbangan antara kompleksitas arsitektur dengan efisiensi operasional model, penelitian ini

diarahkan untuk mengembangkan model prediksi harga komoditas pangan bulanan menggunakan algoritma Linear Regression dan Random Forest Regression. Pendekatan ini diambil karena penerapan arsitektur kombinasi hibrida multi-model yang menggabungkan berbagai algoritma secara simultan terbukti memicu beban komputasi tinggi yang menyulitkan implementasi dinamis [13], sedangkan model statistik konvensional atau ekonometrika linear kerap kali gagal menangkap pola tren nonlinier dari volatilitas harga pangan yang radikal [12]. Dengan menggunakan kombinasi *Linear Regression* sebagai *baseline* tepercaya dan *Random Forest* sebagai algoritma berbasis *ensemble learning*, model tunggal ini mampu memetakan perilaku harga secara kokoh sebagaimana terbukti efektif pada studi komoditas lokal [14].

Celah kedua terkait keterbatasan model canggih berbasis *deep learning* (seperti *Transformer* atau *LSTM-VAE*) yang rentan memunculkan error semu (*false positives*) berupa anomali stasis pada karakteristik pergerakan harga komoditas pangan yang cenderung stabil atau flat [16]. Penelitian ini mengisi celah tersebut dengan menerapkan feature engineering berbasis data historis, meliputi lag features, moving average, perubahan harga, dan persentase perubahan harga untuk meningkatkan representasi pola temporal secara stabil. Risiko bias dieliminasi bukan dengan merumitkan struktur jaringan buatan, melainkan melalui rekayasa inersia harga historis jangka pendek dan jangka menengah yang diakui secara ilmiah bertindak sebagai faktor paling dominan dalam menekan tingkat kesalahan peramalan runtun waktu [12], [17].

Selanjutnya, celah ketiga berkaitan dengan mayoritas penelitian terdahulu yang membangun model menggunakan parameter acak default tanpa adanya optimasi mendalam (Muchtar & Afiyati, 2024) atau terhambat oleh kendala jeda waktu akuisisi data (*data time lag*) yang menurunkan akurasi model pada pusat konsumsi [10], [17]. Penelitian ini secara khusus merancang solusi dengan mengoptimalkan hyperparameter model menggunakan Grid Search, Random Search, dan Bayesian Optimization. Penerapan komparasi tri-optimasi parameter ini ditujukan untuk menjamin penemuan konfigurasi struktur pohon keputusan terbaik dari algoritma *Random Forest* secara otomatis dan presisi demi menekan tingkat kesalahan estimasi ke tingkat paling minimum.

Akhirnya, untuk menjawab celah keempat mengenai keterbatasan ruang lingkup penelitian terdahulu yang umumnya bersifat *single-commodity* berskala lokal [14], hanya mengandalkan satu nilai indeks agregat makro global tunggal [12], serta memiliki keterbatasan lini masa data historis yang belum mencakup eskalasi fluktuasi pasca tahun 2024 [15], penelitian ini berkomitmen untuk membandingkan performa kedua model regresi berdasarkan metrik evaluasi MAE, RMSE, MAPE, dan R^2 Score untuk menentukan model yang paling akurat. Pengujian komparatif berbasis metrik standardisasi internasional ini diimplementasikan secara masif menggunakan pembagian data berbasis waktu (*Time-Based Split*) terupdate hingga April 2026 yang mencakup 47 jenis komoditas pangan retail tingkat konsumen secara

individual. Dengan demikian, luaran dari komparasi metrik evaluasi ini dipastikan mampu memberikan penilaian performa yang transparan, valid, dan objektif dalam mencerminkan kondisi riil gejolak stabilitas pangan nasional.

2.4 Landasan Teori

2.4.1 Machine Learning Regression

Machine learning regression merupakan salah satu kategori utama dalam *supervised learning* atau pembelajaran terawasi yang berfokus pada tugas prediksi nilai numerik kontinu. Berbeda dengan klasifikasi yang memprediksi label kategori diskret, regresi bekerja dengan cara mempelajari pola hubungan fungsional antara variabel prediktor sebagai masukan dan variabel target sebagai luaran. Dalam penerapannya pada sektor ekonomi dan pangan, pendekatan regresi memungkinkan algoritma untuk memetakan tren pergerakan nilai berdasarkan data historis runtun waktu secara kuantitatif. Pemodelan ini bertujuan untuk menghasilkan estimasi seakurat mungkin dengan meminimalkan selisih antara nilai aktual di lapangan dan nilai prediktif yang dihasilkan oleh model [18].

2.4.2 Linear Regression

Linear Regression atau regresi linier merupakan algoritma dasar dalam pemodelan regresi yang mengasumsikan adanya hubungan linier lurus antara variabel bebas dan variabel terikat. Model ini bekerja dengan cara mencari garis regresi terbaik (*best-fit linear line*) melalui estimasi parameter koefisien yang meminimalkan jumlah kuadrat kesalahan atau menggunakan metode *Least Squares* [19].

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k + \epsilon \quad (1)$$

Dalam persamaan 1 tersebut, y melambangkan variabel target numerik yang diprediksi, $x_1, x_2, \dots, x_k$ merupakan fitur-fitur prediktor masukan, β_0 melambangkan konstanta atau *intercept*, β_1 hingga β_k merupakan koefisien kemiringan garis regresi, dan ϵ merepresentasikan nilai kesalahan acak atau *error*. Meskipun regresi linier sangat efisien dari segi waktu komputasi serta memiliki tingkat interpretasi interpretabilitas fitur yang sangat tinggi, algoritma ini memiliki keterbatasan inheren apabila dihadapkan pada karakteristik data riil yang mengandung pola fluktuasi nonlinier dan radikal.

2.4.3 Random Forest Regression

Random Forest Regression merupakan algoritma pembelajaran mesin berbasis *ensemble learning* yang bekerja dengan membangun sekumpulan besar pohon keputusan (*decision trees*) secara simultan pada masa pelatihan data [20]. Algoritma ini menerapkan prinsip *Bootstrap Aggregating* atau *Bagging*, di mana setiap pohon keputusan individu dilatih menggunakan sampel acak berulang dari dataset utama, serta memilih subset fitur acak pada setiap percabangan node pohon keputusan. Langkah acak ganda tersebut sengaja dirancang untuk mereduksi tingkat korelasi antar-pohon sehingga mampu mengatasi kelemahan *overfitting* yang sering terjadi pada pohon keputusan tunggal. Prediksi akhir dari pemodelan regresi ini diperoleh melalui mekanisme penggabungan nilai rata-rata (*averaging*) dari hasil estimasi seluruh pohon yang telah terbentuk. Karakteristik tersebut menjadikan *Random Forest* sangat andal dalam menangani interaksi fitur nonlinier yang kompleks dan memiliki stabilitas prediksi yang tinggi saat menghadapi variasi data runtun waktu [21].

2.4.4 Feature Engineering Berbasis Temporal

Feature engineering merupakan tahapan rekayasa data mentah menjadi bentuk atribut baru yang lebih representatif agar model *machine learning* dapat mempelajari pola perubahan secara optimal [22]. Dalam konteks data runtun waktu atau *time series*, transformasi difokuskan pada pembentukan fitur temporal berbasis kronologis historis. Fitur pertama yang dibentuk adalah *lag features*, yaitu nilai variabel target pada beberapa langkah waktu sebelumnya yang berfungsi untuk menangkap efek ketergantungan tren jangka pendek atau persistensi harga langsung. [22] Fitur kedua adalah *moving average* atau rata-rata bergerak, yang diperoleh dengan menghitung nilai rata-rata dari jendela waktu tertentu untuk menghaluskan fluktuasi acak atau *noise* musiman sehingga model dapat menangkap arah tren jangka menengah maupun jangka panjang secara stabil. Fitur ketiga adalah perubahan harga (*price difference*) dan persentase perubahan harga (*percentage change*) yang merepresentasikan kecepatan, momentum, serta akselerasi fluktuasi nilai dari satu periode ke periode berikutnya, sehingga memperkaya representasi pola temporal sebelum memasuki fase pelatihan model [23].

2.4.5 Teknik Optimasi Hyperparameter

Hyperparameter merupakan parameter konfigurasi model yang nilainya harus ditentukan secara manual sebelum proses pelatihan data dimulai, di mana penentuan nilai ini akan memengaruhi struktur serta performa akhir dari model pembelajaran mesin [24]. Guna menemukan kombinasi parameter terbaik, digunakan teknik optimasi otomatis, di antaranya adalah metode *Grid*

Search yang bekerja melakukan pencarian menyeluruh terhadap seluruh kemungkinan kombinasi parameter yang telah didefinisikan sebelumnya dalam ruang matriks terstruktur [24]. Metode kedua adalah *Random Search* yang memilih kombinasi parameter secara acak dari ruang pencarian berdasarkan distribusi probabilitas tertentu, sehingga membutuhkan waktu komputasi yang lebih efisien dibandingkan *Grid Search* [24]. Metode ketiga adalah *Bayesian Optimization*, yaitu pendekatan optimasi berbasis probabilistik cerdas yang membangun sebuah model fungsi objektif atau *surrogate model* berdasarkan hasil pengujian parameter pada iterasi sebelumnya. Melalui mekanisme evaluasi berbasis riwayat tersebut, *Bayesian Optimization* dapat mengarahkan pencarian parameter berikutnya ke area ruang pencarian yang paling menjanjikan secara efisien [22], [24].

2.4.6 Metrik Evaluasi Regresi

Evaluasi performa model regresi dilakukan dengan mengukur besarnya penyimpangan antara nilai hasil prediksi dan nilai aktual untuk mengetahui tingkat akurasi serta kebaikan model secara objektif [25]. Metrik pertama adalah *Mean Absolute Error* (MAE) yang mengukur rata-rata dari kesalahan absolut tanpa memedulikan arah minus atau plus [26], dengan definisi matematis sebagai berikut:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (2)$$

Metrik kedua adalah *Root Mean Squared Error* (RMSE) yang menghitung akar kuadrat dari rata-rata kuadrat kesalahan, di mana metrik ini memberikan penalti yang jauh lebih berat bagi error yang bernilai besar melalui skema penguadratan selisih [26], dengan rumus matematis sebagai berikut:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (3)$$

Metrik ketiga adalah *Mean Absolute Percentage Error* (MAPE) yang merepresentasikan persentase rata-rata kesalahan absolut terhadap nilai aktualnya, sehingga sangat memudahkan interpretasi tingkat akurasi relatif terhadap skala nilai data [25], dengan persamaan matematis sebagai berikut:

$$MAPE = \frac{100\%}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right| \quad (4)$$

Metrik keempat adalah *Coefficient of Determination* atau R^2 Score yang mengukur kemampuan model dalam menjelaskan besarnya variasi atau variabilitas data terikat aktual melalui variabel prediktor bebas yang digunakan [25], dengan rumus matematis sebagai berikut:

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (5)$$

Dalam seluruh persamaan metrik di atas, n melambangkan jumlah total data pengamatan, y_i melambangkan nilai harga pangan aktual pada data uji, $\hat{y}_i$ melambangkan nilai harga pangan hasil prediksi model machine learning, dan $\bar{y}$ merepresentasikan nilai rata-rata dari keseluruhan data pangan aktual. Model prediktif dinyatakan memiliki performa terbaik apabila mampu meminimalkan nilai error pada metrik MAE, RMSE, dan MAPE, serta menghasilkan skor R^2 yang sedekat mungkin menuju angka satu [25], [26].

BAB III

Metodologi Penelitian

3.1 Metode Penelitian

Penelitian ini menggunakan metode kuantitatif dengan pendekatan *Data Mining* untuk membangun model prediksi harga komoditas pangan bulanan berdasarkan data historis harga. Metode kuantitatif dipilih karena penelitian berfokus pada pengolahan data numerik melalui proses analisis statistik dan pemodelan menggunakan algoritma *machine learning*. Pendekatan ini memungkinkan pengukuran performa model secara objektif menggunakan metrik evaluasi sehingga hasil penelitian dapat dibandingkan secara kuantitatif.

Dalam penelitian ini, proses data *mining* digunakan untuk menggali pola yang terdapat pada data historis harga komoditas pangan sehingga dapat dimanfaatkan untuk memprediksi harga pada periode berikutnya [22]. Data yang digunakan merupakan data historis harga komoditas pangan bulanan yang terdiri atas beberapa atribut, yaitu komoditas, tahun, bulan, dan harga. Variabel harga berperan sebagai variabel target (*dependent variable*), sedangkan atribut lainnya digunakan sebagai variabel prediktor (*independent variable*) yang diperkaya melalui proses *feature engineering* [22].

Penelitian ini menerapkan dua algoritma regresi, yaitu *Linear Regression* dan *Random Forest Regression*. *Linear Regression* digunakan sebagai model dasar (*baseline model*) karena memiliki kemampuan dalam memodelkan hubungan linear antara variabel prediktor dengan variabel target serta mudah diinterpretasikan [19]. Sementara itu, *Random Forest Regression* digunakan karena mampu menangkap hubungan yang lebih kompleks dan *nonlinier* melalui pembentukan banyak pohon keputusan (*decision tree*) yang digabungkan menjadi satu model [21]. Dengan menggunakan kedua algoritma tersebut, penelitian dapat membandingkan performa model sederhana dan model berbasis *ensemble* dalam memprediksi harga komoditas pangan.

3.2 Tahapan Penelitian

Tahapan penelitian merupakan serangkaian proses yang dilakukan secara sistematis mulai dari pengumpulan data hingga diperoleh model prediksi terbaik. Setiap tahapan memiliki tujuan tertentu agar proses analisis dapat berjalan secara terstruktur dan menghasilkan model prediksi yang akurat. Penelitian ini dilakukan melalui beberapa tahapan utama, yaitu pengumpulan data, analisis data, *preprocessing*, *feature engineering*, pembagian dataset, pembangunan model, optimasi *hyperparameter*, evaluasi model, analisis hasil, dan penarikan kesimpulan. Melalui tahapan tersebut diharapkan penelitian ini dapat

menghasilkan model prediksi yang tidak hanya memiliki tingkat akurasi yang baik, tetapi juga mampu memberikan informasi yang bermanfaat sebagai pendukung pengambilan keputusan dalam pengelolaan harga komoditas pangan.

3.2.1 Pengumpulan Data

Tahap pengumpulan data merupakan proses awal yang dilakukan untuk memperoleh dataset yang akan digunakan dalam penelitian. Data yang digunakan pada penelitian ini berupa data historis harga komoditas pangan bulanan. Dataset tersebut memuat informasi mengenai nama komoditas, tahun pencatatan, bulan pencatatan, dan harga komoditas pada setiap periode.

Pengumpulan data dilakukan dengan mengompilasi data harga komoditas pangan dari sumber data yang telah tersedia, kemudian menyusunnya ke dalam satu *dataset* yang terstruktur sehingga siap digunakan pada proses analisis data *mining* [22]. *Dataset* yang digunakan terdiri dari 1.227 baris data dan 4 atribut, yaitu Komoditas, Tahun, Bulan, dan Harga. Atribut Harga digunakan sebagai variabel target yang akan diprediksi, sedangkan atribut lainnya digunakan sebagai variabel masukan (*input features*) dalam proses pemodelan.

Sebelum digunakan dalam proses analisis, *dataset* terlebih dahulu diverifikasi untuk memastikan bahwa data telah tersusun secara lengkap, memiliki format yang konsisten, serta sesuai dengan kebutuhan penelitian. Proses verifikasi meliputi pemeriksaan jumlah data, tipe data setiap atribut, serta kesesuaian nilai pada masing-masing kolom. Tahapan ini bertujuan untuk meminimalkan kesalahan pada proses pengolahan data dan meningkatkan kualitas data yang akan digunakan dalam pemodelan [27].

3.2.2 Analisis Data

Tahap analisis data dilakukan untuk memahami karakteristik dataset sebelum memasuki proses pemodelan. Analisis ini bertujuan untuk mengetahui struktur data, tipe data setiap atribut, distribusi data, serta mengidentifikasi potensi permasalahan seperti *missing value*, data duplikat, inkonsistensi format, maupun nilai ekstrem (*outlier*). Selain itu, dilakukan analisis statistik deskriptif terhadap atribut harga untuk memperoleh informasi mengenai nilai minimum, maksimum, rata-rata, median, dan standar deviasi.

Analisis data juga dilakukan melalui proses *Exploratory Data Analysis (EDA)* menggunakan visualisasi grafik seperti *histogram*, *boxplot*, diagram batang, *line chart*, dan *heatmap*. Melalui proses ini dapat diketahui pola perubahan harga komoditas berdasarkan waktu,

distribusi setiap komoditas, tren harga tahunan, serta hubungan antara variabel yang digunakan. Hasil analisis tersebut menjadi dasar dalam menentukan teknik *preprocessing*, *feature engineering*, dan algoritma yang digunakan pada tahap pembangunan model.

3.2.3 *Preprocessing Data*

Tahap *preprocessing* dilakukan untuk meningkatkan kualitas *dataset* sehingga siap digunakan pada proses *machine learning*. Proses ini bertujuan menghilangkan inkonsistensi data, memperbaiki format data, serta mengubah data menjadi bentuk yang sesuai untuk proses pelatihan model.

Tahapan *preprocessing* yang dilakukan pada penelitian ini meliputi:

1. Membersihkan nama kolom dan data teks dengan menghapus spasi yang tidak diperlukan.
2. Membersihkan atribut harga dari simbol mata uang dan tanda pemisah ribuan, kemudian mengubahnya menjadi tipe numerik.
3. Menangani *missing value* menggunakan metode interpolasi *linier* yang dilanjutkan dengan *forward fill* dan *backward fill* apabila masih terdapat nilai kosong.
4. Mengubah nama bulan menjadi representasi numerik menggunakan teknik encoding.
5. Membentuk atribut tanggal berdasarkan kombinasi tahun dan bulan.
6. Melakukan deteksi *outlier* menggunakan metode *Interquartile Range* (IQR).
7. Melakukan normalisasi fitur numerik menggunakan *StandardScaler* sebelum proses pelatihan model.

Tahapan *preprocessing* dilakukan agar *dataset* memiliki kualitas yang baik sehingga mampu meningkatkan performa model *machine learning*.

3.2.4 *Feature engineering*

Feature engineering merupakan proses membentuk atribut baru berdasarkan informasi yang terdapat pada dataset historis sehingga model dapat mempelajari pola perubahan harga secara lebih efektif.

Pada penelitian ini dibangun beberapa fitur baru yang berasal dari data historis harga komoditas, yaitu:

- a. Harga satu bulan sebelumnya (Lag-1)

- b. Harga dua bulan sebelumnya (Lag-2)
- c. Harga tiga bulan sebelumnya (Lag-3)
- d. *Moving Average* tiga bulan
- e. *Moving Average* enam bulan
- f. Perubahan harga (*Price Difference*)
- g. Persentase perubahan harga (*Percentage Change*)
- h. Target harga bulan berikutnya

Selain itu dilakukan proses *One Hot Encoding* pada atribut komoditas agar data kategorikal dapat digunakan oleh algoritma *machine learning*. Seluruh fitur tersebut diharapkan mampu meningkatkan kemampuan model dalam menangkap pola temporal perubahan harga komoditas pangan.

3.2.5 Pembagian *Dataset*

Setelah seluruh proses *preprocessing* dan *feature engineering* selesai dilakukan, *dataset* dibagi menjadi data latih (*training set*) dan data uji (*testing set*). Pembagian *dataset* dilakukan menggunakan metode *Time-Based Split* dengan komposisi 80% data latih dan 20% data uji [22], [28].

Metode ini dipilih karena penelitian menggunakan data deret waktu (*time series*), sehingga data pada periode sebelumnya digunakan untuk memprediksi data pada periode berikutnya. Pendekatan tersebut dapat menghindari terjadinya kebocoran informasi (*data leakage*) dari masa depan ke proses pelatihan model [22].

Data latih digunakan untuk membangun model *machine learning*, sedangkan data uji digunakan untuk mengevaluasi kemampuan model dalam melakukan prediksi terhadap data yang belum pernah dipelajari sebelumnya.

3.2.6 Pembagian Model

Tahap pembangunan model bertujuan membentuk model *machine learning* yang mampu memprediksi harga komoditas pangan berdasarkan data historis yang telah diproses.

Penelitian ini menggunakan dua algoritma regresi, yaitu:

1. *Linear Regression*

Linear Regression digunakan sebagai model dasar (*baseline model*) untuk mengetahui kemampuan algoritma regresi *linear* dalam memprediksi harga komoditas berdasarkan hubungan *linear* antar variabel.

2. *Random Forest Regression*

Random Forest Regression digunakan sebagai model pembanding karena memiliki kemampuan menangani hubungan *nonlinier*, mengurangi risiko *overfitting*, serta menghasilkan prediksi yang lebih stabil melalui pendekatan *ensemble learning*.

Kedua model dibangun menggunakan dataset yang sama sehingga hasil evaluasi dapat dibandingkan secara objektif.

3.2.7 Optimasi *Hyperparameter*

Setelah model dasar berhasil dibangun, dilakukan proses optimasi *hyperparameter* untuk memperoleh kombinasi parameter terbaik sehingga performa model dapat meningkat.

Metode optimasi yang digunakan meliputi:

- *Grid Search*, yaitu pencarian seluruh kombinasi parameter yang telah ditentukan.
- *Random Search*, yaitu pencarian parameter secara acak dari ruang parameter yang tersedia.
- *Bayesian Optimization*, yaitu metode optimasi berbasis probabilitas yang menentukan kombinasi parameter berikutnya berdasarkan hasil evaluasi sebelumnya.

Pada penelitian ini proses *hyperparameter tuning* difokuskan pada algoritma *Random Forest Regression* karena algoritma tersebut memiliki beberapa parameter yang dapat memengaruhi performa model, seperti jumlah pohon (*n_estimators*), kedalaman pohon (*max_depth*), jumlah minimum sampel pada setiap node (*min_samples_split*), dan parameter lainnya. Hasil optimasi kemudian dibandingkan untuk memperoleh model dengan performa terbaik.

3.2.8 *Pseudocode* Proses Pelatihan dan Optimasi Model

Berdasarkan Tabel 3.1 *pseudocode* digunakan untuk memperjelas alur algoritmik dari proses pelatihan dan optimasi model, digunakan *pseudocode* yang menggambarkan tahapan utama mulai dari preprocessing hingga evaluasi model. *Pseudocode* ini disajikan sebagai representasi

konseptual dari prosedur yang diimplementasikan dalam sistem.

Tabel 3. 1 *Pseudocode*

Input: Dataset hasil preprocessing $D = \{(x_i, y_i)\}$ $x_i = \{\text{Komoditas, Tahun, Bulan, Lag-1, Lag-2, Lag-3,}$ Moving Average 3, Moving Average 6, Price Difference, Percentage Change} $y_i = \text{Harga Bulan Berikutnya}$ Output: Best model M^*, optimal hyperparameters θ^*, best evaluation metrics (MAE*, RMSE*, MAPE*, R^2*), predicted prices $\hat{y}_{\text{test}}$
Phase 1: Data Preparation
Step 1: Feature Selection Select predictor variables X; Select target variable y; Step 2: Dataset Splitting Split dataset using Time-Based Split; Obtain: ($X_{\text{train}}, y_{\text{train}}$) ($X_{\text{test}}, y_{\text{test}}$) Step 3: Feature Scaling Fit StandardScaler using X_{train}; Transform X_{train} and X_{test};
Phase 2: Model Training and Hyperparameter Optimization
Step 4: Baseline Model Training Train Linear Regression model M_{LR} using ($X_{\text{train}}, y_{\text{train}}$); Predict: $\hat{y}_{\text{LR}} \leftarrow M_{\text{LR}}.\text{predict}(X_{\text{test}});$ Compute: MAE_LR, RMSE_LR, MAPE_LR, R^2_{LR};

Step 5: Random Forest Baseline

Train Random Forest model M_{RF} using default parameters;

Predict:

$\hat{y}_{RF} \leftarrow M_{RF}.predict(X_{test});$

Compute:

$MAE_{RF}, RMSE_{RF}, MAPE_{RF}, R^2_{RF};$

Step 6: Grid Search Optimization

Define parameter grid $\Theta_{grid};$

Perform Grid Search using Cross Validation;

Obtain optimal parameters:

θ_{grid}^*

Train optimized Random Forest model using $\theta_{grid}^*;$

Predict:

$\hat{y}_{grid};$

Compute:

$MAE_{grid}, RMSE_{grid},$
 $MAPE_{grid}, R^2_{grid};$

Step 7: Random Search Optimization

Define parameter distributions $\Theta_{random};$

Perform Random Search;

Obtain:

θ_{random}^*

Train optimized Random Forest model;

Predict:

$\hat{y}_{random};$

Compute:

$MAE_{random},$
 $RMSE_{random},$
 $MAPE_{random},$
 $R^2_{random};$

Step 8: Bayesian Optimization

Define search space Θ_{bayes} ;

Initialize Bayesian Optimizer;

Iteratively evaluate candidate parameters;

Obtain:

θ_{bayes}^*

Train optimized Random Forest model;

Predict:

$\hat{y}_{\text{bayes}}$;

Compute:

MAE_{bayes},

RMSE_{bayes},

MAPE_{bayes},

R^2_{bayes} ;

Phase 3: Model Evaluation

Step 9: Model Comparison

Compare all models based on:

Minimum MAE

Minimum RMSE

Minimum MAPE

Maximum R^2

Select

$M^* \leftarrow$ model with best performance

Step 10: Final Prediction

Use M^* to predict testing data:

$\hat{y}_{\text{test}} \leftarrow M^*.\text{predict}(X_{\text{test}})$

Return

M^* ,
 θ^* ,
 MAE^* ,
 $RMSE^*$,
 $MAPE^*$,
 R^{2*} ,
 $\hat{y}_{test}$

3.2.9 Evaluasi model

Setelah proses pelatihan selesai, seluruh model dievaluasi menggunakan data uji. Evaluasi dilakukan untuk mengetahui tingkat akurasi prediksi yang dihasilkan oleh masing-masing algoritma.

Metrik evaluasi yang digunakan pada penelitian ini meliputi:

- a. *Mean Absolute Error (MAE)*, untuk mengukur rata-rata kesalahan absolut antara nilai aktual dan hasil prediksi.

Adapun definisi metrik *MAE* yang digunakan adalah sebagai berikut:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

Keterangan:

- n = jumlah data
- y_i = nilai aktual
- $\hat{y}_i$ = nilai hasil prediksi

- b. *Root Mean Squared Error (RMSE)*, untuk mengukur besarnya kesalahan prediksi dengan memberikan penalti lebih besar terhadap kesalahan yang tinggi.

Adapun definisi metrik *RMSE* yang digunakan adalah sebagai berikut:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

- c. *Mean Absolute Percentage Error (MAPE)*, untuk mengetahui persentase rata-rata kesalahan prediksi terhadap nilai aktual.

Adapun definisi metrik *MAPE* yang digunakan adalah sebagai berikut:

$$MAPE = \frac{100\%}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right|$$

Interpretasi MAPE yang umum digunakan:

Tabel 3. 2 Interpretasi *MAPE*

Nilai <i>MAPE</i>	Interpretasi
< 10%	Sangat baik (<i>Highly Accurate</i>)
10–20%	Baik
20–50%	Cukup
> 50%	Kurang baik

- d. *Coefficient of Determination* (R^2 Score), untuk mengukur kemampuan model dalam menjelaskan variasi data.

Adapun definisi metrik R^2 Score yang digunakan adalah sebagai berikut:

$$R^2 = 1 - \left(\sum_{i=1}^n (y_i - \widehat{y}_i)^2 \right) / \left(\sum_{i=1}^n (y_i - \bar{y})^2 \right)$$

Interpretasi:

- $R^2 = 1 \rightarrow$ prediksi sempurna
- $R^2 \approx 0 \rightarrow$ model tidak mampu menjelaskan variasi data
- Semakin mendekati 1 $\rightarrow$ model semakin baik

Model dengan nilai *MAE*, *RMSE*, dan *MAPE* yang lebih kecil serta nilai R^2 yang mendekati satu (1) dianggap memiliki performa yang lebih baik.

3.2.9 Analisis hasil

Tahap terakhir merupakan analisis terhadap hasil evaluasi seluruh model yang telah dibangun. Analisis dilakukan dengan membandingkan performa *Linear Regression* dan *Random Forest Regression* sebelum maupun sesudah proses optimasi *hyperparameter*.

Selain membandingkan nilai *MAE*, *RMSE*, *MAPE*, dan R^2 Score, dilakukan pula analisis terhadap kemampuan masing-masing model dalam mengikuti pola perubahan harga komoditas

pangan berdasarkan data historis. Hasil analisis digunakan untuk menentukan model terbaik yang memiliki tingkat akurasi tertinggi serta mampu memberikan prediksi harga yang paling mendekati nilai aktual.

Berdasarkan hasil evaluasi tersebut kemudian disusun kesimpulan mengenai efektivitas algoritma yang digunakan serta pengaruh feature engineering dan optimasi *hyperparameter* terhadap peningkatan performa model prediksi harga komoditas pangan.

BAB IV

Hasil dan Pembahasan

4.1 Deskripsi Dataset

Pada penelitian ini digunakan dataset Rata-rata Harga Pangan Bulanan Tingkat Konsumen Nasional yang diperoleh dari portal data terbuka pemerintah Indonesia (*data.go.id*). Dataset ini berisi informasi mengenai rata-rata harga berbagai komoditas pangan yang dikumpulkan setiap bulan pada tingkat konsumen nasional. Data tersebut digunakan sebagai dasar dalam membangun model *machine learning* untuk memprediksi harga komoditas pangan pada periode berikutnya.

Dataset mencakup periode Januari 2021 hingga April 2026, sehingga mampu menggambarkan perubahan harga komoditas pangan dalam rentang waktu lebih dari lima tahun. Data historis ini memungkinkan model pembelajaran mesin mempelajari pola musiman, tren kenaikan maupun penurunan harga, serta fluktuasi harga yang dipengaruhi oleh kondisi ekonomi maupun faktor musiman.

Secara keseluruhan, dataset terdiri dari 1.227 data (*record*) yang mewakili 47 jenis komoditas pangan. Setiap data memiliki empat atribut utama, yaitu nama komoditas, tahun, bulan, dan harga rata-rata. Berdasarkan hasil pemeriksaan struktur dataset menggunakan fungsi *df.info()*, seluruh atribut memiliki jumlah data yang lengkap tanpa adanya nilai kosong (*missing value*). Hal ini menunjukkan bahwa dataset memiliki kualitas yang baik dan siap digunakan pada proses analisis maupun pemodelan.

Tabel 4. 1 Informasi Dataset

Informasi	Keterangan
Nama <i>Dataset</i>	Rata-rata Harga Pangan Bulanan Tingkat Konsumen Nasional
Sumber Data	<i>data.go.id</i>
Periode Data	Januari 2021 – April 2026
Jumlah Data	1.227 <i>record</i>
Jumlah Atribut	4 atribut

Jumlah Komoditas	47 komoditas
Missing Value	Tidak ada
Format Data	CSV

Tabel 4. 2 Tipe Data Dataset

No	Nama Atribut	Tipe Data	Keterangan
1	Komoditas	<i>Object</i>	Nama komoditas pangan yang diamati
2	Tahun	<i>Integer</i>	Tahun pencatatan harga
3	Bulan	<i>Object</i>	Bulan pencatatan harga
4	Harga	<i>Object</i>	Nilai rata-rata harga komoditas pada bulan tertentu

```
# Display the first 5 rows of the DataFrame
display(df.head())
```

	Komoditas	Tahun	Bulan	Harga
0	Beras Premium	2021	Januari	Rp12.319
1	Beras Medium	2021	Januari	Rp10.865
2	Kedelai Biji Kering	2021	Januari	Rp10.607
3	Bawang Merah	2021	Januari	Rp30.329
4	Bawang Putih (Bonggol)	2021	Januari	Rp26.308

Gambar 4. 1 Data Awal Dataset

Berdasarkan Gambar 4.1 dapat dilihat bahwa setiap baris merepresentasikan harga suatu komoditas pada bulan dan tahun tertentu. Sebagai contoh, komoditas Beras Premium pada bulan Januari 2021 memiliki harga sebesar Rp12.319, sedangkan Beras Medium memiliki harga sebesar Rp10.865. Informasi inilah yang nantinya digunakan sebagai dasar pembentukan fitur historis pada proses prediksi.

```
# Display basic information about the Dataset
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1227 entries, 0 to 1226
Data columns (total 4 columns):
#   Column      Non-Null Count  Dtype
---  -
0   Komoditas    1227 non-null   object
1   Tahun        1227 non-null   int64
2   Bulan        1227 non-null   object
3   Harga        1227 non-null   object
dtypes: int64(1), object(3)
memory usage: 38.5+ KB
```

Gambar 4. 2 Struktur Dataset

Berdasarkan Gambar 4.2 diketahui bahwa *dataset* terdiri atas 1.227 baris dan 4 kolom, yaitu Komoditas, Tahun, Bulan, dan Harga. Seluruh atribut memiliki 1.227 nilai *non-null*, sehingga tidak ditemukan data yang hilang (*missing value*). Atribut Komoditas, Bulan, dan Harga bertipe *object*, sedangkan atribut Tahun bertipe *integer (int64)*. Pada tahap *preprocessing*, atribut Harga kemudian dikonversi menjadi tipe numerik agar dapat digunakan dalam proses pelatihan model *machine learning*.

```
# Display descriptive statistics
display(df.describe(include="all"))
```

	Komoditas	Tahun	Bulan	Harga
count	1227	1227.000000	1227	1227
unique	47	NaN	12	1186
top	Cabai Rawit Merah	NaN	Februari	-
freq	64	NaN	120	16
mean	NaN	2023.546862	NaN	NaN
std	NaN	1.522012	NaN	NaN
min	NaN	2021.000000	NaN	NaN
25%	NaN	2022.000000	NaN	NaN
50%	NaN	2024.000000	NaN	NaN
75%	NaN	2025.000000	NaN	NaN
max	NaN	2026.000000	NaN	NaN

Gambar 4. 3 Statistik Deskriptif *Dataset*

Analisis statistik deskriptif dilakukan menggunakan fungsi *describe()* untuk memberikan gambaran umum mengenai karakteristik *dataset*. Hasil analisis ditampilkan pada Gambar 4.3.

Berdasarkan hasil statistik deskriptif diperoleh informasi bahwa dataset mencakup 47 jenis komoditas dengan distribusi data pada 12 bulan dalam satu tahun. Komoditas yang paling sering muncul adalah Cabai Rawit Merah dengan frekuensi sebanyak 64 data, sedangkan bulan yang paling banyak tercatat adalah Februari dengan frekuensi 120 data. Variabel Tahun memiliki nilai minimum 2021, nilai maksimum 2026, serta rata-rata sebesar 2023,55, yang menunjukkan bahwa data relatif tersebar secara merata selama periode pengamatan.

Selain itu, atribut Harga memiliki 1.186 nilai unik, yang menunjukkan bahwa sebagian besar harga komoditas memiliki variasi yang cukup tinggi. Keragaman nilai harga tersebut menjadi salah satu faktor penting dalam membangun model prediksi yang mampu mempelajari pola perubahan harga dari waktu ke waktu.


4.2 Eksplorasi Data (EDA)

Exploratory Data Analysis (EDA) merupakan tahapan awal yang bertujuan untuk memahami karakteristik dataset sebelum dilakukan proses *preprocessing* dan pembangunan model *machine learning*. Melalui *EDA* dapat diketahui distribusi data, pola penyebaran harga, tren perubahan harga, keberadaan *outlier*, serta hubungan antara variabel yang terdapat dalam dataset. Informasi tersebut menjadi dasar dalam menentukan teknik *preprocessing* dan metode pemodelan yang tepat.

Pada penelitian ini dilakukan beberapa analisis eksploratif, yaitu analisis jumlah data berdasarkan komoditas, tahun, dan bulan, distribusi harga komoditas, deteksi *outlier*, analisis rata-rata harga setiap komoditas, analisis tren harga, serta visualisasi hubungan harga berdasarkan tahun dan bulan menggunakan *heatmap*.

4.2.1 Distribusi Data Berdasarkan Komoditas

...




Gambar 4. 4 Jumlah Data per Komoditas

Berdasarkan Gambar 4.4 terlihat bahwa sebagian besar komoditas memiliki jumlah data yang relatif seimbang, yaitu sekitar 64 data untuk setiap komoditas. Hal ini menunjukkan bahwa pencatatan harga dilakukan secara konsisten setiap bulan selama periode pengamatan. Namun, terdapat beberapa komoditas yang memiliki jumlah data lebih sedikit, seperti Minyakita, Beras Khusus (Lokal), dan Beras Medium *Non* SPHP. Perbedaan tersebut kemungkinan disebabkan oleh komoditas yang baru mulai dicatat pada periode tertentu atau adanya perubahan kebijakan dalam pencatatan data.

Distribusi data yang relatif merata pada sebagian besar komoditas memberikan keuntungan dalam proses pelatihan model karena dapat mengurangi risiko bias terhadap komoditas tertentu.

4.2.2 Distribusi Data Berdasarkan Tahun




Gambar 4. 5 Jumlah Data per Tahun

Berdasarkan Gambar 4.5 diketahui bahwa jumlah data mengalami peningkatan dari tahun 2021 hingga 2025. Tahun 2025 memiliki jumlah data terbanyak, yaitu 296 data, sedangkan tahun 2026 memiliki jumlah data paling sedikit, yaitu 108 data. Jumlah data yang lebih sedikit pada tahun 2026 disebabkan karena dataset hanya mencakup periode hingga bulan April.

Distribusi data berdasarkan tahun menunjukkan bahwa dataset memiliki cakupan waktu yang cukup panjang sehingga mampu merepresentasikan perubahan harga komoditas pangan dalam jangka waktu lebih dari lima tahun.

4.2.3 Distribusi Data Berdasarkan Bulan




Gambar 4. 6 Jumlah Data per Bulan

Berdasarkan Gambar 4.6 terlihat bahwa bulan Februari, Maret, dan April memiliki jumlah data terbanyak yaitu sekitar 120 data, sedangkan bulan Mei hingga Desember memiliki jumlah data sekitar 93–94 data. Perbedaan jumlah data antarbulan terjadi karena dataset tahun 2026 hanya tersedia hingga bulan April.

Meskipun terdapat sedikit perbedaan jumlah data, distribusi data bulanan masih cukup representatif untuk menggambarkan pola perubahan harga komoditas sepanjang tahun.

4.2.4 Distribusi Harga Komoditas




Gambar 4. 7 Distribusi Harga Komoditas

Distribusi nilai harga komoditas divisualisasikan menggunakan histogram pada Gambar 4.7.

Histogram menunjukkan bahwa sebagian besar harga komoditas berada pada kisaran Rp10.000 hingga Rp40.000. Frekuensi data semakin menurun pada harga yang lebih tinggi sehingga distribusi data cenderung miring ke kanan (*right-skewed*). Hal ini menunjukkan bahwa sebagian besar komoditas memiliki harga relatif rendah, sedangkan hanya sedikit komoditas yang memiliki harga sangat tinggi.

Distribusi yang tidak simetris ini mengindikasikan adanya variasi harga yang cukup besar antar komoditas sehingga diperlukan analisis lebih lanjut terhadap keberadaan *outlier*.

4.2.5 Analisis *Outlier* Menggunakan *Boxplot*




Gambar 4. 8 *Boxplot* Harga Komoditas

Visualisasi boxplot ditunjukkan pada Gambar 4.8. Berdasarkan *boxplot* terlihat bahwa sebagian besar data berada pada rentang harga sekitar Rp10.000 hingga Rp40.000. Namun demikian, terdapat sejumlah titik yang berada jauh di atas whisker sehingga menunjukkan adanya outlier.

Outlier tersebut berasal dari beberapa komoditas yang memang memiliki harga relatif tinggi dibandingkan komoditas lainnya, seperti daging sapi maupun daging kerbau. Karena nilai tersebut masih mencerminkan kondisi harga yang sebenarnya, maka data tidak dihapus agar informasi penting mengenai variasi harga tetap dipertahankan.

4.2.6 Rata-rata Harga Setiap Komoditas




Gambar 4. 9 Rata-rata Harga per Komoditas

Perbandingan rata-rata harga masing-masing komoditas ditampilkan pada Gambar 4.9 Grafik menunjukkan bahwa Daging Kerbau Segar (Lokal) memiliki rata-rata harga tertinggi, diikuti oleh Daging Sapi Murni dan Daging Kerbau Beku (Impor). Sebaliknya, komoditas seperti Jagung TK. Peternak, Tepung Terigu Curah, dan Garam Konsumsi memiliki rata-rata harga yang relatif rendah.

Perbedaan rata-rata harga antar komoditas menunjukkan bahwa setiap komoditas memiliki karakteristik harga yang berbeda. Oleh karena itu, informasi historis menjadi faktor penting dalam proses prediksi harga.

4.2.7 Tren Rata-rata Harga Berdasarkan Tahun




Gambar 4. 10 Tren Rata-rata Harga per Tahun

Perubahan rata-rata harga setiap tahun ditunjukkan pada Gambar 4.10. Berdasarkan grafik terlihat bahwa rata-rata harga mengalami fluktuasi selama periode pengamatan. Setelah mengalami sedikit penurunan pada tahun 2023–2024, rata-rata harga meningkat cukup signifikan pada tahun 2025 sebelum kembali mengalami sedikit penurunan pada tahun 2026.

Perubahan tersebut menunjukkan bahwa harga komoditas pangan dipengaruhi oleh berbagai faktor seperti inflasi, kondisi pasokan, permintaan pasar, maupun kebijakan pemerintah.

4.2.8 Tren Harga Beberapa Komoditas




Gambar 4. 11 Tren Harga Beberapa Komoditas

Perubahan harga beberapa komoditas utama selama periode penelitian ditunjukkan pada Gambar 4.11. Grafik memperlihatkan bahwa setiap komoditas memiliki pola perubahan harga yang berbeda. Komoditas Bawang Merah mengalami fluktuasi yang cukup tinggi dibandingkan komoditas lain, sedangkan Beras Premium dan Beras Medium menunjukkan perubahan harga yang relatif lebih stabil.

Perbedaan pola tersebut mengindikasikan bahwa model prediksi harus mampu mempelajari karakteristik historis masing-masing komoditas agar menghasilkan prediksi yang lebih akurat.

4.2.9 Heatmap Rata-rata Harga Berdasarkan Tahun dan Bulan



Gambar 4. 12 Heatmap Rata-rata Harga per Tahun dan Bulan

Visualisasi hubungan rata-rata harga berdasarkan tahun dan bulan ditampilkan pada Gambar 4.12. Heatmap menunjukkan adanya variasi rata-rata harga pada setiap kombinasi tahun dan bulan. Warna yang semakin terang menunjukkan rata-rata harga yang semakin tinggi, sedangkan warna yang lebih gelap menunjukkan rata-rata harga yang lebih rendah.

Terlihat bahwa tahun 2025 didominasi oleh warna yang lebih terang dibandingkan tahun-tahun sebelumnya, yang mengindikasikan bahwa rata-rata harga komoditas pada tahun tersebut relatif lebih tinggi. Visualisasi ini memperlihatkan adanya perubahan harga dari waktu ke waktu sehingga mendukung penggunaan pendekatan *time series* dalam proses prediksi.

4.3 Preprocessing

Tahap *preprocessing* merupakan proses persiapan data sebelum digunakan dalam pembangunan model machine learning. Tujuan utama dari tahap ini adalah meningkatkan kualitas data, mengurangi potensi kesalahan selama proses pelatihan model, serta menghasilkan fitur yang lebih representatif terhadap pola harga komoditas pangan. Pada penelitian ini, proses *preprocessing* meliputi pembersihan data, penanganan *missing value*, transformasi tipe data, pembuatan fitur (*feature engineering*), *encoding*, pembentukan data latih dan data uji, serta penyimpanan hasil *preprocessing*.

4.3.1 *Cleaning* Nama Kolom dan Data Teks

Tahap pertama adalah melakukan pembersihan nama kolom dan data bertipe teks. Pembersihan dilakukan untuk menghilangkan spasi yang tidak diperlukan (*leading* maupun *trailing whitespace*) pada nama kolom serta nilai pada atribut Komoditas dan Bulan.

Langkah ini bertujuan untuk menjaga konsistensi data sehingga tidak terjadi perbedaan penulisan yang dapat menyebabkan kesalahan pada proses pengelompokan (*grouping*) maupun *encoding*.

```
Nama kolom setelah cleaning:
['Komoditas', 'Tahun', 'Bulan', 'Harga']
Jumlah komoditas setelah cleaning: 28
Daftar bulan setelah cleaning:
['Januari' 'Februari' 'Maret' 'April' 'Mei' 'Juni' 'Juli' 'Agustus'
 'September' 'Oktober' 'November' 'Desember']
```

Gambar 4. 13 Hasil Cleaning Nama Kolom dan Data Teks

Hasil proses menunjukkan bahwa nama kolom berhasil dibersihkan menjadi Komoditas, Tahun, Bulan, dan Harga, sedangkan nama bulan telah tersusun dengan format yang konsisten dari Januari hingga Desember.

4.3.2 *Cleaning* Kolom Harga

Kolom Harga pada dataset masih berupa data bertipe teks yang mengandung simbol mata uang (*Rp*), tanda titik sebagai pemisah ribuan, serta beberapa karakter lain yang tidak diperlukan. Oleh karena itu dilakukan proses pembersihan dengan menghapus seluruh karakter *non-numerik*, kemudian mengubah nilai kosong menjadi *NaN* sebelum dikonversi ke dalam tipe data numerik (*float*). Tahapan ini dilakukan agar data harga dapat diproses dalam perhitungan statistik maupun algoritma machine learning.

	Komoditas	Tahun	Bulan	Harga
169	Minyak Goreng Curah	2022	Januari	NaN
170	Jagung Tk. Peternak	2022	Januari	NaN
184	Minyak Goreng Curah	2022	Februari	NaN
185	Jagung Tk. Peternak	2022	Februari	NaN
199	Minyak Goreng Curah	2022	Maret	NaN
200	Jagung Tk. Peternak	2022	Maret	NaN
215	Jagung Tk. Peternak	2022	April	NaN
348	Tepung Terigu Kemasan	2023	Januari	NaN
352	Ikan Kembung	2023	Januari	NaN
353	Ikan Tongkol	2023	Januari	NaN
354	Ikan Bandeng	2023	Januari	NaN
355	Garam konsumsi	2023	Januari	NaN
368	Tepung Terigu Kemasan	2023	Februari	NaN
375	Garam konsumsi	2023	Februari	NaN
388	Tepung Terigu Kemasan	2023	Maret	NaN
395	Garam konsumsi	2023	Maret	NaN

Gambar 4. 14 Hasil Cleaning Kolom Harga

4.3.3 Penanganan *Missing Value*

Setelah proses konversi harga menjadi numerik, ditemukan 16 data yang memiliki nilai kosong (*missing value*). Penanganan *missing value* dilakukan menggunakan metode interpolasi *linier* (*linear interpolation*) pada masing-masing komoditas. Metode ini memperkirakan nilai yang hilang berdasarkan pola perubahan harga pada periode sebelumnya dan sesudahnya.

Apabila masih terdapat nilai kosong setelah interpolasi, maka dilakukan proses *forward fill* (*ffill*) dan *backward fill* (*bfill*) sehingga seluruh data memiliki nilai yang lengkap. Hasil proses menunjukkan bahwa jumlah *missing value* berhasil dikurangi dari 16 data menjadi 0 data, sehingga dataset siap digunakan pada tahap selanjutnya.

```
Missing Harga sebelum imputasi: 16
Missing Harga setelah imputasi: 0
```

Gambar 4. 15 Penanganan Missing Value

4.3.4 Statistik Harga Setelah Cleaning

Setelah proses pembersihan selesai, dilakukan analisis statistik deskriptif terhadap kolom harga

untuk memastikan kualitas data yang akan digunakan. Statistik yang dihitung meliputi nilai minimum, maksimum, rata-rata, simpangan baku (*standard deviation*), serta jumlah data pada setiap komoditas. Analisis ini memberikan gambaran mengenai karakteristik harga masing-masing komoditas sebelum dilakukan proses pembentukan fitur.

	Komoditas	Jumlah_Data	Harga_Min	Harga_Rata_Rata	Harga_Max	Harga_Std
12	Daging Kerbau Segar (Lokal)	15	140557.0	141881.066667	144686.0	1387.470230
13	Daging Sapi Murni	64	121836.0	133266.328125	141350.0	4774.770045
11	Daging Kerbau Beku (Impor)	15	105220.0	108166.666667	117260.0	3807.435314
9	Cabai Rawit Merah	64	35465.0	58045.406250	92656.0	13662.674476
7	Cabai Merah Besar	15	38269.0	47073.933333	54278.0	4998.236453
8	Cabai Merah Keriting	64	28052.0	46410.609375	76189.0	10095.949145
17	Ikan Kembung	40	38235.0	40836.850000	46233.0	1923.913327
0	Bawang Merah	64	24403.0	36547.656250	57859.0	6918.365408
10	Daging Ayam Ras	64	33457.0	36443.625000	41312.0	1727.411427
16	Ikan Bandeng	40	33523.0	35597.425000	38691.0	1373.396200
18	Ikan Tongkol	40	32244.0	35154.625000	38462.0	1661.089242
1	Bawang Putih (Bonggol)	64	25701.0	34834.703125	44750.0	6051.821323
25	Telur Ayam Ras	64	22611.0	28370.500000	31923.0	2295.623061

Gambar 4. 16 Statistik Harga Setelah Cleaning

4.3.5 Encoding Bulan

Atribut Bulan awalnya masih berbentuk data kategorikal berupa nama bulan. Karena algoritma machine learning hanya dapat memproses data numerik, maka dilakukan proses *encoding* dengan mengubah nama bulan menjadi representasi angka sebagai berikut. Setelah proses *encoding*, seluruh data bulan berhasil dikonversi tanpa menghasilkan nilai kosong.

Tabel 4. 3 Encoding Bulan

Bulan	Nilai
Januari	1
Februari	2
Maret	3

April	4
Mei	5
Juni	6
Juli	7
Agustus	8
September	9
Oktober	10
November	11
Desember	12

4.3.6 Pembuatan Kolom Tanggal

Untuk mempermudah analisis berbasis waktu (*time series*), atribut Tahun dan Bulan digabungkan menjadi satu atribut baru yaitu Tanggal. Kolom ini digunakan sebagai dasar dalam proses pengurutan data secara kronologis serta pembagian data latih dan data uji berdasarkan waktu. Setelah kolom tanggal berhasil dibuat, dataset diurutkan berdasarkan Komoditas dan Tanggal.

4.3.7 Deteksi Outlier

Tahap berikutnya adalah mendeteksi data yang memiliki nilai ekstrem menggunakan metode Interquartile Range (IQR). Pada metode ini dihitung nilai kuartil pertama (Q1), kuartil ketiga (Q3), serta nilai IQR menggunakan persamaan:

$$IQR=Q3-Q1$$

Data dikategorikan sebagai *outlier* apabila memenuhi salah satu kondisi berikut.

$$\text{Harga} < Q1 - 1.5 \times IQR$$

atau

$$\text{Harga} > Q3 + 1.5 \times IQR$$

Hasil deteksi menunjukkan adanya beberapa data *outlier*. Namun, data tersebut tidak dihapus karena masih mencerminkan kondisi harga sebenarnya pada komoditas tertentu, terutama komoditas dengan harga relatif tinggi.

4.3.8 Feature Engineering

Tahap *feature engineering* dilakukan untuk menghasilkan fitur-fitur baru yang mampu merepresentasikan pola historis perubahan harga komoditas. Fitur yang dibentuk berasal dari data harga pada periode sebelumnya sehingga model dapat mempelajari hubungan antara harga saat ini dengan harga pada periode berikutnya.

Adapun fitur yang digunakan pada penelitian ini ditunjukkan pada Tabel 4.4.

Tabel 4. 4 Fitur Hasil Feature Engineering

No	Fitur	Fungsi
1	Harga <i>Lag-1</i>	Harga satu bulan sebelumnya
2	Harga <i>Lag-2</i>	Harga dua bulan sebelumnya
3	Harga <i>Lag-3</i>	Harga tiga bulan sebelumnya
4	<i>Moving Average 3</i>	Rata-rata harga tiga bulan sebelumnya
5	<i>Moving Average 6</i>	Rata-rata harga enam bulan sebelumnya
6	Perubahan Harga	Selisih harga bulan berjalan dengan bulan sebelumnya
7	Persentase Perubahan Harga	Persentase perubahan harga terhadap bulan sebelumnya

8	Target Harga Bulan Berikutnya	Harga yang akan diprediksi pada periode selanjutnya
---	-------------------------------	---

Setelah seluruh fitur terbentuk, dilakukan penghapusan baris data yang masih memiliki nilai kosong akibat proses pembentukan fitur *lag*, *moving average*, maupun target prediksi. Tahap ini menghasilkan dataset yang lengkap dan siap digunakan dalam proses pelatihan model.

	Komoditas	Tanggal	Harga	Perubahan_Harga	Persentase_Perubahan_Harga
0	Bawang Merah	2021-01-01	30329.0	NaN	NaN
1	Bawang Merah	2021-02-01	29996.0	-333.0	-1.097959
2	Bawang Merah	2021-03-01	33050.0	3054.0	10.181358
3	Bawang Merah	2021-04-01	31729.0	-1321.0	-3.996974
4	Bawang Merah	2021-05-01	31355.0	-374.0	-1.178732
5	Bawang Merah	2021-06-01	29914.0	-1441.0	-4.595758
6	Bawang Merah	2021-07-01	31897.0	1983.0	6.629003
7	Bawang Merah	2021-08-01	32657.0	760.0	2.382669
8	Bawang Merah	2021-09-01	28890.0	-3767.0	-11.535046
9	Bawang Merah	2021-10-01	28004.0	-886.0	-3.066805
10	Bawang Merah	2021-11-01	26510.0	-1494.0	-5.334952
11	Bawang Merah	2021-12-01	26854.0	344.0	1.297624
12	Bawang Merah	2022-01-01	28672.0	1818.0	6.769941
13	Bawang Merah	2022-02-01	31832.0	3160.0	11.021205
14	Bawang Merah	2022-03-01	35044.0	3212.0	10.090475

Gambar 4. 17 Hasil Feature Engineering

4.3.9 Encoding Komoditas

Variabel Komoditas merupakan atribut kategorikal sehingga dilakukan proses *One Hot Encoding* menggunakan fungsi *get_dummies()*. Proses ini mengubah setiap jenis komoditas menjadi atribut biner bernilai 0 atau 1.

Penggunaan *One Hot Encoding* bertujuan agar informasi mengenai jenis komoditas tetap dapat dimanfaatkan oleh model tanpa memberikan hubungan urutan antar kategori. Setelah proses *encoding*, diperoleh sejumlah fitur baru yang mewakili masing-masing komoditas.

4.3.10 Pembagian Data Latih dan Data Uji

Setelah seluruh proses *preprocessing* selesai dilakukan, dataset dibagi menjadi data latih (*training set*) dan data uji (*testing set*). Pembagian dilakukan menggunakan metode Time-Based Split dengan komposisi 80% data latih dan 20% data uji berdasarkan urutan waktu.

Pendekatan ini dipilih karena penelitian menggunakan data deret waktu (*time series*), sehingga data pada periode sebelumnya digunakan untuk memprediksi data pada periode berikutnya. Dengan metode ini, model tidak memperoleh informasi dari data masa depan selama proses pelatihan.

Hasil pembagian data ditunjukkan pada Tabel 4.5.

Tabel 4. 5 Pembagian Data Latih dan Data Uji

Keterangan	Nilai
Data Latih	760 data
Data Uji	280 data
Periode Data Latih	Juli 2021 – Maret 2025
Periode Data Uji	April 2025 – Maret 2026
Metode Split	Time-Based Split (80:20)

Selain itu, dilakukan proses *scaling* terhadap fitur numerik menggunakan StandardScaler. Tahap ini bertujuan untuk menyamakan skala antar fitur sehingga model yang sensitif terhadap perbedaan skala, seperti Linear Regression, dapat menghasilkan performa yang lebih optimal.

4.3.1 Hasil *Preprocessing*

Berdasarkan seluruh tahapan *preprocessing* yang telah dilakukan, dataset berhasil dibersihkan dari data yang tidak konsisten, seluruh *missing value* berhasil ditangani, serta data kategorikal telah ditransformasikan menjadi format numerik yang dapat diproses oleh algoritma machine learning. Selain itu, dilakukan pembentukan fitur-fitur historis melalui proses *feature engineering* yang diharapkan mampu meningkatkan kemampuan model dalam mempelajari pola perubahan harga komoditas pangan.

Dataset hasil *preprocessing* kemudian dibagi menjadi data latih dan data uji menggunakan pendekatan *time-based split* sehingga siap digunakan pada tahap pembangunan dan evaluasi model prediksi.

4.4 Pembuatan Model

Tahap pembuatan model bertujuan untuk membangun model machine learning yang mampu memprediksi harga komoditas pangan pada periode berikutnya berdasarkan data historis yang telah melalui proses *preprocessing*. Pada penelitian ini digunakan dua algoritma regresi, yaitu Linear Regression dan Random Forest Regression. Kedua algoritma dipilih karena memiliki karakteristik yang berbeda, sehingga hasil prediksi dapat dibandingkan untuk menentukan model dengan performa terbaik.

Selain membangun model dasar, penelitian ini juga menerapkan beberapa metode *hyperparameter tuning* untuk meningkatkan performa model, yaitu Grid Search, Random Search, dan Bayesian Optimization.

4.4.1 *Linear Regression*

Model pertama yang digunakan adalah Linear Regression, yaitu algoritma regresi yang memprediksi nilai target berdasarkan hubungan linier antara variabel independen dan variabel dependen. Linear Regression dipilih karena memiliki proses pelatihan yang sederhana, waktu komputasi yang cepat, serta mampu menjadi model dasar (*baseline model*) untuk membandingkan performa algoritma lainnya. Pada penelitian ini, Linear Regression menggunakan seluruh fitur hasil *preprocessing*, meliputi fitur numerik, fitur historis (*lag*), *moving average*, perubahan harga, serta hasil *One Hot Encoding* dari atribut komoditas.

4.4.2 *Random Forest Regression*

Model kedua yang digunakan adalah *Random Forest Regression*. Algoritma ini merupakan metode

ensemble learning yang membangun banyak pohon keputusan (*decision tree*) kemudian menggabungkan hasil prediksi seluruh pohon menggunakan metode rata-rata (*averaging*).

Random Forest dipilih karena memiliki kemampuan yang baik dalam menangani hubungan nonlinier, mengurangi risiko *overfitting*, serta mampu menghasilkan prediksi yang lebih stabil dibandingkan model regresi linier. Pada penelitian ini Random Forest dibangun menggunakan data hasil *preprocessing* yang sama dengan Linear Regression sehingga kedua model dapat dibandingkan secara adil.

4.4.3 Hyperparameter Tuning

Untuk memperoleh performa model yang optimal, dilakukan proses *hyperparameter tuning*. Tujuan dari proses ini adalah mencari kombinasi parameter terbaik sehingga model mampu menghasilkan tingkat kesalahan prediksi yang lebih rendah.

Pada penelitian ini digunakan tiga metode *hyperparameter tuning*, yaitu:

a. Grid Search

Grid Search melakukan pencarian seluruh kombinasi parameter yang telah ditentukan sebelumnya (*exhaustive search*). Setiap kombinasi diuji menggunakan data pelatihan, kemudian dipilih kombinasi dengan performa terbaik. Metode ini mampu menghasilkan parameter yang optimal, namun membutuhkan waktu komputasi yang relatif lebih lama.

b. Random Search

Random Search memilih kombinasi parameter secara acak dari ruang pencarian (*parameter space*). Pendekatan ini lebih efisien dibandingkan *Grid Search* karena tidak menguji seluruh kombinasi parameter. Walaupun lebih cepat, Random Search tetap mampu menghasilkan performa yang kompetitif pada berbagai kasus machine learning.

c. Bayesian Optimization

Bayesian Optimization merupakan metode optimasi yang memilih kombinasi parameter berikutnya berdasarkan hasil evaluasi sebelumnya.

Pendekatan ini memanfaatkan model probabilistik untuk memperkirakan kombinasi parameter yang paling menjanjikan sehingga proses pencarian menjadi lebih efisien dibandingkan *Grid Search*

maupun *Random Search*. Metode ini sangat sesuai digunakan ketika jumlah parameter yang akan dioptimasi cukup banyak.

4.4.4 Alur Pembuatan Model

Proses pembangunan model pada penelitian ini dilakukan melalui beberapa tahapan mulai dari data hasil *preprocessing* hingga menghasilkan model terbaik.

Tahapan tersebut meliputi:

- 1) Dataset hasil *preprocessing* digunakan sebagai data masukan.
- 2) Dataset dibagi menjadi data latih dan data uji menggunakan metode *Time-Based Split*.
- 3) Data latih digunakan untuk melatih model Linear Regression dan Random Forest Regression.
- 4) Setiap model dioptimasi menggunakan Grid Search, Random Search, dan Bayesian Optimization.
- 5) Model terbaik dipilih berdasarkan hasil evaluasi menggunakan metrik MAE, RMSE, MAPE, dan R^2 .

4.4.5 Ringkasan Model

Tabel 4.6 merangkum algoritma dan metode optimasi yang digunakan pada penelitian.

Tabel 4. 6 Model yang Digunakan

Algoritma	<i>Hyperparameter Tuning</i>	Tujuan
<i>Linear Regression</i>	Tanpa tuning	Model dasar (<i>baseline</i>)
<i>Random Forest Regression</i>	Tanpa tuning	Membandingkan performa awal
<i>Random Forest Regression</i>	<i>Grid Search</i>	Mencari parameter terbaik secara menyeluruh

<i>Random Forest Regression</i>	<i>Random Search</i>	Mencari parameter terbaik secara acak
<i>Random Forest Regression</i>	<i>Bayesian Optimization</i>	Optimasi parameter berbasis probabilitas

4.5 Hasil Prediksi

Setelah proses pelatihan model selesai dilakukan, setiap model digunakan untuk memprediksi harga komoditas pangan pada data uji (*testing set*). Proses prediksi dilakukan menggunakan dua algoritma, yaitu *Linear Regression* dan *Random Forest Regression*, dengan tiga metode *hyperparameter tuning*, yaitu *Grid Search*, *Random Search*, dan *Bayesian Optimization*. Seluruh model kemudian dibandingkan berdasarkan hasil prediksi terhadap data aktual.

Hasil prediksi menunjukkan bahwa setiap model mampu mengikuti pola perubahan harga komoditas pangan, namun tingkat akurasi yang dihasilkan berbeda. Model *Linear Regression* menghasilkan prediksi yang cukup baik pada data dengan pola hubungan *linier*, tetapi performanya menurun ketika menghadapi fluktuasi harga yang lebih kompleks. Sebaliknya, *Random Forest Regression* mampu menghasilkan prediksi yang lebih stabil karena dapat menangkap hubungan nonlinier antar fitur.

Untuk meningkatkan performa model, dilakukan proses *hyperparameter tuning*. Pada algoritma *Linear Regression*, penerapan *Grid Search*, *Random Search*, dan *Bayesian Optimization* menghasilkan performa yang relatif serupa pada data uji. Sementara itu, pada algoritma *Random Forest Regression*, ketiga metode *tuning* mampu meningkatkan kualitas prediksi dibandingkan model *Linear Regression*, dengan hasil terbaik diperoleh pada metode *Grid Search*.


Tabel 4. 7 Hasil Prediksi Setiap Model

Model	<i>Hyperparameter Tuning</i>	<i>MAE</i>	<i>RMSE</i>	<i>MAPE</i> (%)	<i>R</i> ²
<i>Linear Regression</i>	<i>Grid Search</i>	4634.90	12120.24	9.39	0.8775
<i>Linear Regression</i>	<i>Random Search</i>	4634.90	12120.24	9.39	0.8775
<i>Linear Regression</i>	<i>Bayesian Optimization</i>	4634.90	12120.24	9.39	0.8775
<i>Random Forest Regression</i>	<i>Grid Search</i>	2028.19	4566.37	3.67	0.9826

<i>Random Regression</i>	<i>Forest</i>	<i>Random Search</i>	2135.08	4890.55	3.78	0.9800
<i>Random Regression</i>	<i>Forest</i>	<i>Bayesian Optimization</i>	2028.19	4566.37	3.67	0.9826

Berdasarkan Tabel 4.7, algoritma *Random Forest Regression* memberikan hasil prediksi yang lebih baik dibandingkan *Linear Regression* pada seluruh metode *hyperparameter tuning*. Hal ini terlihat dari nilai *MAE*, *RMSE*, dan *MAPE* yang lebih kecil, serta nilai R^2 yang lebih tinggi. Model terbaik diperoleh dari *Random Forest Regression* dengan *Grid Search*, yang menghasilkan nilai *MAE* sebesar 2028,19, *RMSE* sebesar 4566,37, *MAPE* sebesar 3,67%, dan R^2 sebesar 0,9826. Nilai tersebut menunjukkan bahwa model mampu menjelaskan sekitar 98,26% variasi data harga komoditas pangan pada data uji.

Selain memiliki tingkat kesalahan prediksi yang rendah, model *Random Forest Regression* dengan *Grid Search* juga menunjukkan performa yang konsisten selama proses pelatihan dan pengujian. Oleh karena itu, model tersebut dipilih sebagai model terbaik dan digunakan sebagai dasar analisis lebih lanjut pada tahap evaluasi.



Gambar 4. 18 Perbandingan Nilai Aktual dan Hasil Prediksi Model Terbaik

4.6 Evaluasi Model

Evaluasi model dilakukan untuk mengukur tingkat akurasi hasil prediksi yang dihasilkan oleh setiap algoritma. Pada penelitian ini digunakan empat metrik evaluasi, yaitu *Mean Absolute Error (MAE)*, *Root Mean Squared Error (RMSE)*, *Mean Absolute Percentage Error (MAPE)*, dan *Coefficient of Determination (R^2)*. Keempat metrik tersebut dipilih karena mampu memberikan gambaran mengenai

besar kecilnya kesalahan prediksi serta kemampuan model dalam menjelaskan variasi data aktual.

Secara umum, model yang baik memiliki nilai *MAE*, *RMSE*, dan *MAPE* yang kecil, sedangkan nilai R^2 mendekati 1. Oleh karena itu, seluruh model dibandingkan berdasarkan keempat metrik tersebut untuk menentukan model dengan performa terbaik.

Tabel 4. 8 Hasil Prediksi Setiap Model

Model	Hyperparameter Tuning	MAE	RMSE	MAPE (%)	R^2
<i>Linear Regression</i>	<i>Grid Search</i>	4634.90	12120.24	9.39	0.8775
<i>Linear Regression</i>	<i>Random Search</i>	4634.90	12120.24	9.39	0.8775
<i>Linear Regression</i>	<i>Bayesian Optimization</i>	4634.90	12120.24	9.39	0.8775
<i>Random Forest Regression</i>	<i>Grid Search</i>	2028.19	4566.37	3.67	0.9826
<i>Random Forest Regression</i>	<i>Random Search</i>	2135.08	4890.55	3.78	0.9800
<i>Random Forest Regression</i>	<i>Bayesian Optimization</i>	2028.19	4566.37	3.67	0.9826

Berdasarkan Tabel 4.8, terlihat bahwa algoritma *Random Forest Regression* memberikan performa yang lebih baik dibandingkan *Linear Regression* pada seluruh metode *hyperparameter tuning*. Hal ini ditunjukkan oleh nilai *MAE* dan *RMSE* yang lebih kecil, yang berarti rata-rata kesalahan prediksi lebih rendah dibandingkan model *Linear Regression*.

Model *Linear Regression* menghasilkan nilai *MAE* sebesar 4634,90 dan *RMSE* sebesar 12120,24 pada data uji. Nilai tersebut menunjukkan bahwa model masih mengalami penyimpangan prediksi yang cukup besar terhadap harga aktual. Meskipun nilai *MAPE* sebesar 9,39% masih termasuk kategori baik (di bawah 10%), nilai R^2 sebesar 0,8775 menunjukkan bahwa model hanya mampu menjelaskan sekitar 87,75% variasi data harga komoditas.

Sebaliknya, algoritma *Random Forest Regression* memberikan hasil yang lebih baik. Model dengan metode *Grid Search* menghasilkan nilai *MAE* sebesar 2028,19, *RMSE* sebesar 4566,37, *MAPE* sebesar 3,67%, dan R^2 sebesar 0,9826. Nilai tersebut menunjukkan bahwa rata-rata kesalahan prediksi relatif kecil dan model mampu menjelaskan sekitar 98,26% variasi harga komoditas pada data uji.

Metode Random Search juga memberikan performa yang sangat baik dengan nilai *MAE* sebesar

2135,08, *RMSE* sebesar 4890,55, *MAPE* sebesar 3,78%, dan R^2 sebesar 0,9800. Meskipun sedikit lebih rendah dibandingkan *Grid Search*, hasil tersebut masih menunjukkan tingkat akurasi yang tinggi.

Sementara itu, metode *Bayesian Optimization* pada *Random Forest Regression* menghasilkan performa yang hampir sama dengan *Grid Search*, yaitu *MAE* sebesar 2028,19, *RMSE* sebesar 4566,37, *MAPE* sebesar 3,67%, dan R^2 sebesar 0,9826. Hasil ini menunjukkan bahwa kedua metode optimasi mampu menemukan kombinasi parameter yang memberikan performa terbaik pada model *Random Forest Regression*.

Secara keseluruhan, hasil evaluasi menunjukkan bahwa algoritma *Random Forest Regression* lebih mampu mempelajari hubungan yang kompleks dan pola historis perubahan harga komoditas dibandingkan *Linear Regression*. Hal ini disebabkan *Random Forest* dapat menangani hubungan nonlinier antar fitur serta mengurangi risiko *overfitting* melalui mekanisme *ensemble* dari banyak pohon keputusan. Dengan demikian, *Random Forest Regression* dipilih sebagai model terbaik dalam penelitian ini.

BAB V

Penutup

5.1 Kesimpulan

Berdasarkan hasil penelitian mengenai prediksi harga komoditas pangan bulanan menggunakan algoritma *Linear Regression* dan *Random Forest Regression*, diperoleh beberapa kesimpulan sebagai berikut.

1. Model prediksi harga komoditas pangan berhasil dibangun menggunakan algoritma *Linear Regression* dan *Random Forest Regression* melalui tahapan pengumpulan data, *preprocessing*, *feature engineering*, pembagian *dataset*, pembangunan model, optimasi *hyperparameter*, hingga evaluasi model. Seluruh tahapan tersebut menghasilkan model yang mampu memprediksi harga komoditas berdasarkan data historis.
2. Penerapan *feature engineering* berupa *lag features*, *moving average*, perubahan harga, dan persentase perubahan harga mampu meningkatkan representasi pola temporal pada data. Fitur-fitur tersebut membantu model mempelajari hubungan antara harga pada periode sebelumnya dengan harga pada periode berikutnya sehingga menghasilkan prediksi yang lebih akurat.
3. Optimasi *hyperparameter* menggunakan metode *Grid Search*, *Random Search*, dan *Bayesian Optimization* memberikan peningkatan performa pada algoritma *Random Forest Regression*. Berdasarkan hasil evaluasi, metode *Grid Search* dan *Bayesian Optimization* menghasilkan performa terbaik dengan nilai evaluasi yang sama, sedangkan *Random Search* memberikan hasil yang sedikit lebih rendah namun tetap menunjukkan akurasi yang baik.
4. Berdasarkan perbandingan seluruh model, *Random Forest Regression* memberikan performa terbaik dibandingkan *Linear Regression*. Model *Random Forest Regression* dengan *Grid Search* maupun *Bayesian Optimization* menghasilkan nilai *MAE* sebesar 2028,19, *RMSE* sebesar 4566,37, *MAPE* sebesar 3,67%, dan R^2 sebesar 0,9826. Nilai tersebut menunjukkan bahwa model mampu menjelaskan sekitar 98,26% variasi data harga komoditas pangan dengan tingkat kesalahan prediksi yang relatif rendah. Oleh karena itu, *Random Forest Regression* dinilai lebih efektif dalam memprediksi harga komoditas pangan bulanan dibandingkan *Linear Regression*.

5.2 Saran

Berdasarkan hasil penelitian yang telah dilakukan, terdapat beberapa saran yang dapat dijadikan acuan untuk penelitian selanjutnya, yaitu sebagai berikut.

1. Menambahkan variabel yang memengaruhi harga komoditas, seperti inflasi, cuaca, produksi pertanian, dan kebijakan pemerintah, agar model dapat menghasilkan prediksi yang lebih akurat.
2. Mencoba algoritma prediksi lainnya, seperti *XGBoost*, *LightGBM*, atau *LSTM*, untuk membandingkan performanya dengan *Linear Regression* dan *Random Forest Regression* sehingga dapat diperoleh model yang lebih optimal.
3. Mengembangkan hasil penelitian menjadi aplikasi prediksi harga komoditas pangan yang dapat dimanfaatkan oleh pemerintah, pelaku usaha, maupun masyarakat sebagai pendukung pengambilan keputusan dalam memantau dan memperkirakan perubahan harga komoditas.

Daftar Pustaka

- [1] L. Sari, N. Achسانی, B. Sartono, and L. Anggraeni, "Investigating The Asymmetric Effect of Food Commodity Price on The Volatility in Indonesia," *Jurnal Manajemen dan Agribisnis*, vol. 20, Jul. 2023, doi: 10.17358/jma.20.3.440.
- [2] M. K. Adjemian, S. Arita, S. Meyer, and D. Salin, "Factors affecting recent food price inflation in the United States," *Appl. Econ. Perspect. Policy*, vol. 46, no. 2, pp. 648–676, Jun. 2024, doi: 10.1002/aepp.13378.
- [3] G. Zhou, "Data Mining for Co-Location Patterns; Principles and Applications," 2022.
- [4] F. Rozi *et al.*, "Indonesian foodstuffs in facing global food crisis: Economic aspects of soybean farming," *J. Agric. Food Res.*, vol. 19, Mar. 2025, doi: 10.1016/j.jafr.2025.101669.
- [5] A. Javed, "Benchmarking econometric, decomposable additive, and neural network methods for food inflation prediction featuring policy insights," *Sci. Rep.*, vol. 16, no. 1, p. 5460, 2026, doi: 10.1038/s41598-026-34993-w.
- [6] M. Murtani, D. Kobi, and I. Imelda, "Multi-Commodity Food Price Forecasting Ahead of Eid Al-Fitr in Indonesia (2026–2030): A Comparative Study of Machine Learning Algorithms Using Time-Series Data," *MALCOM: Indonesian Journal of Machine Learning and Computer Science*, vol. 6, no. 1, pp. 404–413, 2026.
- [7] D. R. Lestari, E. A. S. Bangun, F. L. Gaol, and T. Matsuo, "Machine Learning-Based Forecasting of Agricultural Commodity Prices Using Ensemble Models," *Journal of Human, Earth, and Future*, vol. 6, no. 4, pp. 887–899, 2025, doi: 10.28991/HEF-2025-06-04-09.
- [8] H. Yan, M. Manfredo, and A. K. Mishra, "Forecasting for food price inflation using machine learning methodology: Expansion on FRED-MD," *Food Policy*, vol. 140, p. 103077, 2026, doi: <https://doi.org/10.1016/j.foodpol.2026.103077>.
- [9] D. Iliadis, M. Wever, B. De Baets, and W. Waegeman, "Hyperparameter optimization of two-branch neural networks in multi-target prediction," *Appl. Soft Comput.*, vol. 165, p. 111957, 2024, doi: <https://doi.org/10.1016/j.asoc.2024.111957>.
- [10] M. E. Suaza-Medina, F. J. Zarazaga-Soria, J. Pinilla-Lopez, F. J. Lopez-Pellicer, and J. Lacasta, "Effects of data time lag in a decision-making system using machine learning for pork price prediction," *Neural Comput. Appl.*, vol. 35, no. 26, pp. 19221–19233, Sep. 2023, doi: 10.1007/s00521-023-08730-7.
- [11] R. Fadillah, M. Ula, and R. Suwanda, "Machine Learning to Predict Food Prices in Aceh Province Using the Fuzzy Time Series Method Based on Average," *Sinkron : jurnal dan penelitian teknik*

- informatika*, vol. 9, no. 2, pp. 755–761, 2025, doi: 10.33395/sinkron.v9i2.14649.
- [12] T. Ulussever, H. M. Ertuğrul, S. Kılıç Depren, M. T. Kartal, and Ö. Depren, “Estimation of Impacts of Global Factors on World Food Prices: A Comparison of Machine Learning Algorithms and Time Series Econometric Models,” *Foods*, vol. 12, no. 4, Feb. 2023, doi: 10.3390/foods12040873.
 - [13] Y. Guo *et al.*, “Agricultural Price Prediction Based on Combined Forecasting Model under Spatial-Temporal Influencing Factors,” *Sustainability (Switzerland)*, vol. 14, no. 17, Sep. 2022, doi: 10.3390/su141710483.
 - [14] I. Rasyid Muchtar, “Comparison of Linear Regression and Random Forest Algorithms for Premium Rice Price Prediction (Case Study: West Java),” *Jurnal Indonesia Sosial Teknologi*, vol. 5, no. 7, p. 3122, 2024, [Online]. Available: <http://jst.publikasiindonesia.id/>
 - [15] S. Sifriyani, M. Rasjid, D. Rosadi, S. Anwar, R. D. Wahyuni, and S. Jalaluddin, “Spatial-Temporal Epidemiology of COVID-19 Using a Geographically and Temporally Weighted Regression Model,” *Symmetry (Basel)*, vol. 14, no. 4, Apr. 2022, doi: 10.3390/sym14040742.
 - [16] E. Sediyo, K. D. Hartomo, C. Arthur, I. Utami, R. Prabowo, and R. Chiong, “An integrated framework for multi-commodity agricultural price forecasting and anomaly detection using attention-boosted models,” *J. Agric. Food Res.*, vol. 22, Aug. 2025, doi: 10.1016/j.jafr.2025.102021.
 - [17] D. Odion *et al.*, “Towards improving farmers livelihood in Nigeria using food price forecasting,” *J. Agric. Food Res.*, vol. 24, Dec. 2025, doi: 10.1016/j.jafr.2025.102365.
 - [18] P. Pandit *et al.*, “Hybrid time series models with exogenous variable for improved yield forecasting of major Rabi crops in India,” *Sci. Rep.*, vol. 13, no. 1, Dec. 2023, doi: 10.1038/s41598-023-49544-w.
 - [19] Y.-A. Wang, Q. Huang, Z. Yao, and Y. Zhang, “On a class of linear regression methods,” *J. Complex.*, vol. 82, p. 101826, 2024, doi: <https://doi.org/10.1016/j.jco.2024.101826>.
 - [20] Z. Zhou, C. Qiu, and Y. Zhang, “A comparative analysis of linear regression, neural networks and random forest regression for predicting air ozone employing soft sensor models,” *Sci. Rep.*, vol. 13, no. 1, Dec. 2023, doi: 10.1038/s41598-023-49899-0.
 - [21] M. Sun, A. Gong, X. Zhao, N. Liu, L. Si, and S. Zhao, “Reconstruction of a Monthly 1 km NDVI Time Series Product in China Using Random Forest Methodology,” *Remote Sens. (Basel)*, vol. 15, no. 13, Jul. 2023, doi: 10.3390/rs15133353.
 - [22] S. Meisenbacher *et al.*, “Review of automated time series forecasting pipelines,” Nov. 01, 2022, *John Wiley and Sons Inc.* doi: 10.1002/widm.1475.
 - [23] W. Chen, W. Hussain, F. Cauteruccio, and X. Zhang, “Deep Learning for Financial Time Series Prediction: A State-of-the-Art Review of Standalone and Hybrid Models,” 2023, *Tech Science Press*. doi: 10.32604/cmcs.2023.031388.

- [24] A. Morales-Hernández, I. Van Nieuwenhuysse, and S. Rojas Gonzalez, “A survey on multi-objective hyperparameter optimization algorithms for machine learning,” *Artif. Intell. Rev.*, vol. 56, no. 8, pp. 8043–8093, Aug. 2023, doi: 10.1007/s10462-022-10359-2.
- [25] H. Khoshvaght, R. R. Permala, A. Razmjou, and M. Khiadani, “A critical review on selecting performance evaluation metrics for supervised machine learning models in wastewater quality prediction,” Dec. 01, 2025, *Elsevier Ltd.* doi: 10.1016/j.jece.2025.119675.
- [26] T. O. Hodson, “Root-mean-square error (RMSE) or mean absolute error (MAE): when to use them or not,” Jul. 19, 2022, *Copernicus GmbH.* doi: 10.5194/gmd-15-5481-2022.
- [27] V. Werner de Vargas, J. A. Schneider Aranda, R. dos Santos Costa, P. R. da Silva Pereira, and J. L. Victória Barbosa, “Imbalanced data preprocessing techniques for machine learning: a systematic mapping study,” *Knowl. Inf. Syst.*, vol. 65, no. 1, pp. 31–57, Jan. 2023, doi: 10.1007/s10115-022-01772-8.
- [28] V. R. Joseph, “Optimal ratio for data splitting,” *Stat. Anal. Data Min.*, vol. 15, no. 4, pp. 531–538, Aug. 2022, doi: 10.1002/sam.11583.

