

Prediksi Harga Komoditas Pangan Bulanan Menggunakan Pendekatan Machine Learning Regression Berbasis Fitur Temporal

Ode Andi Alamsyah ^{*1}, Rendy Kamaluddin², Nesya Salma Rahmadhani ³, Indah Diva Gracia ⁴

^{1,2,3,4}School of Information Technology, Bachelor of Applied Informatics, University of Logistics and International

Email: ¹714230032@std.ulbi.ac.id, ²rd24rk@gmail.ac.id, ³nesyasr@gmail.com, ⁴indahdivagracia@gmail.com

^{*}Penulis Korespondensi

(Naskah masuk: dd mmm yyyy, diterima untuk diterbitkan: dd mmm yyyy)

Abstrak

Penelitian ini bertujuan untuk memprediksi harga komoditas pangan bulanan menggunakan pendekatan machine learning regression berbasis fitur temporal. Data yang digunakan merupakan rata-rata harga pangan bulanan tingkat konsumen nasional pada periode Januari 2021 hingga April 2026 yang terdiri dari 1.227 data dan 47 komoditas. Tahapan penelitian meliputi preprocessing data, penanganan missing value, transformasi data, feature engineering berupa lag features, moving average, price difference, dan percentage change, serta pembagian data menggunakan time-based split. Model yang digunakan dalam penelitian ini adalah Linear Regression dan Random Forest Regression, yang kemudian dievaluasi menggunakan metrik Mean Absolute Error (MAE), Root Mean Squared Error (RMSE), Mean Absolute Percentage Error (MAPE), dan R Score. Selain itu, dilakukan optimasi hyperparameter menggunakan Grid Search, Random Search, dan Bayesian Optimization untuk meningkatkan performa model. Hasil penelitian menunjukkan bahwa penerapan fitur temporal mampu membantu model dalam menangkap pola perubahan harga dari waktu ke waktu sehingga menghasilkan prediksi yang lebih baik. Penelitian ini diharapkan dapat menjadi referensi dalam analisis dan perencanaan terkait harga komoditas pangan.

Kata kunci: prediksi harga, komoditas pangan, machine learning, regresi, fitur temporal.

Monthly Food Commodity Price Prediction Using Machine Learning Regression Approaches Based on Temporal Features

Abstract

This study aims to predict monthly food commodity prices using a machine learning regression approach based on temporal features. The dataset consists of the national average monthly consumer food prices in Indonesia from January 2021 to April 2026, comprising 1,227 records covering 47 food commodities. The research methodology includes data preprocessing, missing value handling, data transformation, and feature engineering through lag features, moving averages, price differences, and percentage changes. The dataset is then divided into training and testing sets using a time-based split approach. Two regression models, namely Linear Regression and Random Forest Regression, are employed and evaluated using Mean Absolute Error (MAE), Root Mean Squared Error (RMSE), Mean Absolute Percentage Error (MAPE), and the coefficient of determination (R^2 Score). Furthermore, hyperparameter optimization is performed using Grid Search, Random Search, and Bayesian Optimization to improve model performance. The results indicate that incorporating temporal features enables the models to better capture historical price patterns, resulting in more accurate predictions. This study is expected to serve as a valuable reference for food commodity price analysis and support decision-making in food price planning and monitoring.

Keywords: food commodity price prediction, machine learning, regression, temporal feature engineering, Random Forest Regression, hyperparameter optimization.

1. PENDAHULUAN

Indonesia saat ini sangat membutuhkan pendekatan prediktif dalam pengambilan keputusan karena fluktuasi harga pangan terus menjadi tantangan utama yang mengancam stabilitas ekonomi

nasional, ketahanan pangan, dan daya beli masyarakat (Hertini et al., 2026). Fluktuasi harga komoditas strategis seperti beras, cabai, bawang merah, minyak goreng, dan gula pasir masih sering terjadi akibat perubahan musim, gangguan produksi,

distribusi, maupun dinamika permintaan pasar (Bahtiar & Raswatie, 2023). Berdasarkan data Badan Pusat Statistik (BPS), inflasi Indonesia pada Juni 2026 mencapai 3,34%, meningkat dari 3,08% pada Mei 2026. Bank Indonesia juga melaporkan bahwa kelompok *volatile food* masih menjadi penyumbang utama inflasi, terutama akibat kenaikan harga bahan pokok. Kondisi tersebut menunjukkan bahwa fluktuasi harga pangan masih menjadi tantangan yang memerlukan pendekatan prediktif untuk mendukung pengambilan keputusan.

Prediksi harga pangan memiliki peran strategis bagi pemerintah, pelaku usaha, dan masyarakat dalam mendukung pengendalian inflasi, pengelolaan distribusi, serta perencanaan pengeluaran rumah tangga (Sari et al., 2023). Perkembangan machine learning memungkinkan peningkatan akurasi prediksi melalui pemanfaatan pola historis, tren musiman, dan hubungan nonlinier yang sulit dimodelkan menggunakan metode statistik konvensional (Yan et al., 2026).

Berbagai penelitian terdahulu telah menerapkan algoritma machine learning untuk memprediksi harga komoditas pangan. Algoritma Random Forest, XGBoost, LSTM, Gradient Boosting, ARIMA-GARCH, maupun Fuzzy Time Series dilaporkan mampu menghasilkan tingkat akurasi yang baik pada berbagai jenis komoditas dan wilayah penelitian (Javed, 2026; Ogol et al., 2025). Penelitian di Indonesia juga menunjukkan bahwa model ensemble dan deep learning efektif digunakan untuk memprediksi harga komoditas tertentu (Fadillah et al., 2025; Murtani et al., 2026), sedangkan penelitian internasional menegaskan bahwa performa model meningkat ketika informasi historis diperkaya dengan fitur temporal maupun variabel ekonomi pendukung (Lestari et al., 2025). Selain itu, beberapa penelitian menyatakan bahwa proses hyperparameter optimization berkontribusi dalam meningkatkan kemampuan generalisasi model, terutama pada algoritma berbasis ensemble (Iliadis et al., 2024).

Meskipun demikian, penelitian sebelumnya masih memiliki beberapa keterbatasan. Sebagian besar penelitian hanya berfokus pada satu komoditas atau wilayah tertentu sehingga belum mampu merepresentasikan dinamika harga pangan nasional secara menyeluruh. Selain itu, sebagian penelitian hanya membandingkan satu jenis algoritma tanpa mengevaluasi secara sistematis pengaruh feature engineering temporal maupun optimasi hyperparameter. Padahal, pembentukan fitur historis seperti lag features, moving average, price difference, dan percentage change berpotensi meningkatkan kemampuan model dalam menangkap pola perubahan harga dari waktu ke waktu. Di sisi lain, evaluasi beberapa metode optimasi hyperparameter pada dataset harga pangan nasional masih relatif terbatas sehingga efektivitas masing-masing pendekatan belum banyak dikaji secara komprehensif (Iliadis et al., 2024; Javed, 2026; Murtani et al.,

2026). Selain keterbatasan tersebut, literatur terkini juga mengonfirmasi adanya kelemahan pada pemodelan berskala makro global yang menggunakan indeks tunggal karena gagal menangkap volatilitas eceran riil tingkat konsumen domestik (Ulussever et al., 2023). Di samping itu, perancangan arsitektur deep learning (seperti Transformer dan LSTM-VAE) maupun model hibrida kombinasi multi-proses tidak hanya membutuhkan intensitas komputasi dan penalaan parameter yang sangat rumit (Guo et al., 2022), melainkan juga rentan memunculkan penyimpangan prediksi semu (false positives) berupa deteksi anomali stasis ketika dipaksa memetakan komoditas pangan yang berkarakteristik flat atau stabil (Sediyono et al., 2025). Permasalahan ini diperkuat oleh pengabaian terhadap efek jeda waktu akuisisi data (data time lag) yang terbukti meningkatkan noise pada rangkaian data panjang (Suaza-Medina et al., 2023), serta mayoritas rentang waktu pengamatan berkala pada model terdahulu telah terhenti sebelum terjadinya eskalasi guncangan inflasi pangan nasional sepanjang tahun 2025 hingga awal 2026 (Sediyono et al., 2025; Sifriyani et al., 2022).


Berdasarkan permasalahan tersebut, penelitian ini mengusulkan pendekatan prediksi harga komoditas pangan bulanan menggunakan machine learning regression berbasis feature engineering temporal. Dataset yang digunakan merupakan data rata-rata harga pangan bulanan tingkat konsumen nasional Indonesia periode Januari 2021 hingga April 2026 yang mencakup 47 komoditas dengan total 1.227 data. Penelitian membandingkan Linear Regression sebagai model baseline dengan Random Forest Regression sebagai model ensemble. Selain itu, dilakukan optimasi menggunakan Grid Search, Random Search, dan Bayesian Optimization untuk memperoleh konfigurasi model yang optimal.

Penelitian ini berkontribusi melalui integrasi feature engineering temporal, perbandingan Linear Regression dan Random Forest Regression, serta evaluasi Grid Search, Random Search, dan Bayesian Optimization pada dataset harga pangan nasional yang mencakup 47 komoditas. Diharapkan hasil penelitian ini dapat menjadi tumpuan dalam pengembangan model prediksi harga pangan sekaligus mendukung pengambilan keputusan terkait pengendalian inflasi dan distribusi pangan.

2. METODE PENELITIAN

Penelitian ini menerapkan pendekatan yang memanfaatkan metode machine learning untuk memprediksi harga komoditas pangan bulanan berdasarkan data historis (Meisenbacher et al., 2022). Gambar 1 menunjukkan arsitektur sistem yang diusulkan. Kerangka kerja ini mengikuti alur berurutan yang memanfaatkan menggunakan pendekatan time-based split melalui pra-pemrosesan, pembuatan fitur, pelatihan model machine learning, optimasi hyperparameter, dan evaluasi menyeluruh.

Arsitektur ini memastikan modularitas dan memungkinkan perbandingan yang adil di antara model dan strategi optimasi yang berbeda.



Gambar 1. Tahapan Penelitian

2.1. Pengumpulan Data

Penelitian ini secara khusus berfokus untuk memprediksi pergerakan harga komoditas sebagai target utama dengan menerapkan pendekatan machine learning (Sari et al., 2023). Guna mencapai akurasi tersebut, model dibangun menggunakan dataset rata-rata harga pangan bulanan tingkat konsumen nasional yang bersumber langsung dari portal Satu Data Indonesia. (Sari et al., 2023). Data ini mencakup periode Januari 2021 hingga April 2026 dengan total 1.227 catatan historis yang terdiri dari 47 label komoditas strategis. Data disusun dalam empat variabel utama, yaitu nama komoditas, tahun, bulan, dan nilai harga.

Komoditas	Tahun	Bulan	Harga (Rp)
Beras Medium	2021	Januari	10.650
Beras Medium	2021	Februari	10.700
Minyak Goreng Curah	2021	Januari	13.800
...	...	...	...
Cabai Merah Keriting	2026	Maret	52.450
Cabai Merah Keriting	2026	April	49.800

2.2. Pre-pemrosesan Data

Pada tahap ini *preprocessing* bertujuan untuk meningkatkan data sebelum digunakan. Proses ini memastikan data konsisten, bebas dari kesalahan, dan sesuai untuk model. Tahapannya meliputi penanganan *missing value*, penghapusan data duplikat, transformasi tipe data, pengurutan berdasarkan waktu, dan normalisasi format harga.

Pada tahap awal, dilakukan pemeriksaan terhadap *missing value* pada setiap atribut. Nilai yang hilang ditangani menggunakan metode *forward fill*

agar kontinuitas data historis tetap terjaga. Selanjutnya dilakukan pengecekan terhadap data duplikat untuk menghindari pengaruh pengulangan data terhadap proses pelatihan model. Atribut Tahun dan Bulan kemudian dikonversi menjadi format tanggal (*datetime*) sehingga data dapat diurutkan secara kronologis sesuai karakteristik deret waktu (*time series*).

Selain itu, atribut harga yang semula masih berbentuk teks dikonversi menjadi tipe data numerik agar dapat diproses oleh algoritma regresi. Setelah seluruh tahapan *preprocessing* selesai dilakukan, diperoleh dataset siap digunakan pada tahap *feature engineering*.

2.3. Feature Engineering

Feature engineering dilakukan untuk membentuk fitur baru dari data historis sehingga model mampu menangkap pola perubahan harga komoditas pangan secara lebih efektif (Meisenbacher et al., 2022). Pada penelitian ini, digunakan fitur temporal yang memanfaatkan informasi harga pada periode sebelumnya karena karakteristik data deret waktu memiliki ketergantungan antarperiode (Guo et al., 2022; Sifriyani et al., 2022).

Fitur temporal yang dibangun meliputi *lag features* (*Lag-1*, *Lag-2*, dan *Lag-3*), *moving average*, *price difference*, dan *percentage change*. *Lag features* merepresentasikan harga pada satu hingga tiga periode sebelumnya sehingga model dapat mempelajari hubungan historis terhadap harga pada periode berikutnya (Pandit et al., 2023; Suaza-Medina et al., 2023). *Moving average* digunakan untuk merepresentasikan tren harga jangka pendek, sedangkan *price difference* dan *percentage change* digunakan untuk menggambarkan perubahan harga secara absolut maupun relatif antarperiode. Kombinasi fitur-fitur tersebut diharapkan mampu meningkatkan kemampuan model dalam mengenali pola tren dan fluktuasi harga.

Fitur *Lag-1* digunakan untuk merepresentasikan harga komoditas pada satu periode sebelumnya (Chen et al., 2023). Secara matematis, fitur tersebut dapat dirumuskan sebagai berikut.

$$Lag_{1,t} = y_{t-1} \quad (1)$$

Pada persamaan (1), y_{t-1} menyatakan harga komoditas pada periode sebelumnya. Selanjutnya, *Moving Average* digunakan untuk menggambarkan tren harga jangka pendek dengan menghitung rata-rata harga pada tiga periode sebelumnya.

$$MA_t = \frac{y_{t-1} + y_{t-2} + y_{t-3}}{3} \quad (2)$$

Persamaan (2), MA_t merupakan nilai moving average pada periode ke- t . Kemudian untuk menangkap perubahan harga antarperiode, penelitian ini membentuk fitur *Price Difference* yang dihitung menggunakan selisih harga antara periode berjalan

dan periode sebelumnya, sebagaimana ditunjukkan pada Persamaan (3).

$$PD_t = y_t - y_{t-1} \quad (3)$$

Pada persamaan (3), PD merupakan perubahan absolut harga komoditas pada periode ke- t . Selanjutnya membentuk fitur *Percentage Change* yang mewakili perubahan harga dibandingkan periode sebelumnya.

$$PC_t = \frac{y_t - y_{t-1}}{y_{t-1}} \times 100\% \quad (4)$$

Pada persamaan (4), PCt menyatakan persentase perubahan harga komoditas pada periode ke- t .

2.4. Pembagian Dataset

Pada tahap ini metode time-based split dipilih karena dataset yang digunakan merupakan *time series*, sehingga urutan kronologis data harus dipertahankan agar tidak terjadi *data leakage*. Berbeda dengan *random split*, metode *time-based split* memastikan bahwa data pada periode sebelumnya hanya digunakan untuk memprediksi data pada periode berikutnya sehingga lebih mencerminkan kondisi nyata dalam proses prediksi (Joseph, 2022; Meisenbacher et al., 2022).

Pada penelitian ini data dibagi menjadi partisi pelatihan dan pengujian dengan rasio 80:20. Data latih digunakan untuk membangun model, sedangkan data uji digunakan untuk mengevaluasi model dalam melakukan prediksi terhadap data yang belum pernah digunakan selama proses pelatihan sebelumnya (Chen et al., 2023). Skema pembagian tersebut diharapkan mampu memberikan hasil evaluasi yang lebih objektif serta merepresentasikan kemampuan generalisasi model terhadap data baru.

2.5. Pemodelan Machine Learning Regression

Setelah proses *preprocessing*, *feature engineering*, dan pembagian data selesai dilakukan, tahap berikutnya adalah membangun model prediksi menggunakan algoritma *machine learning regression*. Penelitian ini membandingkan *Linear Regression* sebagai model *baseline* dengan *Random Forest Regression* sebagai model *ensemble*. *Linear Regression* dipilih karena sederhana dan mudah diinterpretasikan, sedangkan *Random Forest Regression* digunakan karena mampu memodelkan hubungan nonlinier melalui pendekatan *ensemble* sehingga berpotensi menghasilkan performa prediksi yang lebih baik.

2.5.1. Linear Regression

Linear Regression diterapkan untuk memodelkan hubungan linier antara variabel independen dengan variabel dependen (Wang et al., 2024). Persamaan *Linear Regression* dapat dituliskan sebagai berikut.

$$\hat{y} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p \quad (4)$$

dengan $\hat{y}$ menyatakan nilai prediksi, β_0 merupakan konstanta (*intercept*), β_i adalah koefisien regresi, dan x_i merupakan variabel prediktor..

2.5.2 Random Forest Regression

Random Forest Regression adalah algoritma berbasis *ensemble learning* yang menghasilkan prediksi berdasarkan rata-rata keluaran sejumlah *decision tree* yang dibangun secara independent (Zhou et al., 2023). Prediksi pada *Random Forest Regression* dihitung menggunakan persamaan berikut.

$$\hat{y} = \frac{1}{K} \sum_{k=1}^K T_k(X) \quad (5)$$

Pada persamaan 5, $\hat{y}$ menyatakan nilai prediksi, K adalah jumlah *decision tree*, dan $T_k(X)$ merupakan hasil prediksi dari pohon ke- k . *Random Forest Regression* dipilih sebagai model utama karena mampu menangkap hubungan *nonlinier* serta memiliki ketahanan yang baik terhadap *noise* dan *outlier* (Rasyid Muchtar, 2024; Sun et al., 2023).

2.6. Optimasi Hyperparameter

Optimasi *hyperparameter* dilakukan untuk memperoleh konfigurasi parameter terbaik yang dapat meningkatkan performa model. Optimasi parameternya meliputi *n_estimators*, *max_depth*, *min_samples_split*, dan *min_samples_leaf*, karena parameter-parameter tersebut berpengaruh terhadap kompleksitas model dan akurasi prediksi.

Penelitian ini mencoba tiga optimasi, yaitu *Grid Search*, *Random Search*, dan *Bayesian Optimization*. *Grid Search* mengevaluasi seluruh kombinasi parameter yang telah ditentukan, *Random Search* memilih kombinasi parameter secara acak, sedangkan *Bayesian Optimization* menggunakan pendekatan probabilistik untuk mengarahkan proses pencarian menuju kombinasi parameter yang memberikan performa terbaik. Seluruh proses optimasi dilakukan menggunakan *cross-validation* pada data latih untuk memperoleh konfigurasi model yang optimal sebelum dilakukan evaluasi pada data uji.

Tabel 2. Hyperparameter Random Forest Regression

Hyperparameter	Deskripsi
<i>n_estimators</i>	Jumlah pohon keputusan yang dibangun.
<i>max_depth</i>	Kedalaman maksimum setiap pohon keputusan.
<i>min_samples_split</i>	Jumlah minimum sampel untuk melakukan pemisahan node.
<i>min_samples_leaf</i>	Jumlah minimum sampel pada setiap daun pohon.

2.7. Evaluasi Model

Evaluasi kinerja prediksi harga komoditas dilakukan dengan menggunakan beberapa metrik evaluasi, yaitu Mean Absolute Error, Root Mean Squared Error, Mean Absolute Percentage Error, dan Coefficient of Determination. Penggunaan beberapa metrik ini diharapkan dapat memberikan analisis yang komprehensif terhadap tingkat kesalahan prediksi dan variasi data.

Mean Absolute Error (MAE) digunakan untuk mengukur rata-rata selisih absolut antara nilai aktual dan nilai prediksi. Nilai yang semakin kecil menunjukkan bahwa hasil prediksi semakin mendekati nilai sebenarnya (Hodson, 2022). MAE dihitung menggunakan Persamaan (7).

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (7)$$

Root Mean Squared Error (RMSE) digunakan untuk mengukur besarnya kesalahan prediksi dengan memberikan penalti yang lebih besar terhadap kesalahan yang memiliki nilai tinggi (Hodson, 2022). Nilai RMSE dihitung menggunakan Persamaan (8).

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (8)$$

Selanjutnya, *Mean Absolute Percentage Error* (MAPE) digunakan untuk mengukur rata-rata persentase kesalahan prediksi terhadap nilai aktual sehingga memudahkan interpretasi tingkat akurasi model (Khoshvaght et al., 2025). Persamaan MAPE ditunjukkan pada Persamaan (9).

$$MAPE = \frac{100}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right| \quad (9)$$

Selain itu, kemampuan model dalam menjelaskan variasi data diukur menggunakan *Coefficient of Determination* (R^2). Nilai R^2 berada pada rentang 0 hingga 1, di mana nilai yang semakin mendekati 1 menunjukkan bahwa model memiliki kemampuan yang semakin baik dalam merepresentasikan hubungan antara variabel prediktor dan variabel target (Hodson, 2022; Khoshvaght et al., 2025). Persamaan R^2 ditunjukkan pada Persamaan (10).

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \bar{y})^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (10)$$

dengan y_i menyatakan nilai aktual, $\hat{y}_i$ adalah nilai prediksi, $\bar{y}$ merupakan rata-rata nilai aktual, dan n adalah jumlah data pengujian. Model terbaik ditentukan berdasarkan nilai MAE, RMSE, dan MAPE yang paling kecil serta nilai R^2 yang paling mendekati 1 (Hodson, 2022; Khoshvaght et al., 2025).

2.8. Pseudocode

Algoritma 1 menyajikan pseudocode alur dari proses pelatihan dan optimasi model, digunakan pseudocode yang menggambarkan tahapan utama mulai dari preprocessing hingga evaluasi model. Pseudocode ini disajikan sebagai representasi konseptual dari prosedur yang diimplementasikan dalam system.


Algorithm 1: End-to-End Pipeline of Machine Learning Regression Berbasis Fitur Temporal
Input : $D = \{(c, y, m, p)\}$, c = commodity, y = year, m = month, p = commodity price Output : M_{best}
Phase 1 : Data Preparation $D \leftarrow \text{Clean}(D)$ $p \leftarrow \text{ImputeMissing}(p)$ $m \leftarrow \text{EncodeMonth}(m)$ $t \leftarrow \text{Date}(y, m)$ $D \leftarrow \text{Sort}(D, t)$
Phase 2 : Feature Engineering $\forall c_i \in \text{Commodity do}$ $\text{Lag}_1 \leftarrow p_{t-1}$ $\text{Lag}_2 \leftarrow p_{t-2}$ $\text{Lag}_3 \leftarrow p_{t-3}$ $MA_3 \leftarrow \frac{p_{t-1} + p_{t-2} + p_{t-3}}{3}$ $MA_6 \leftarrow \frac{\sum_{i=1}^6 p_{t-i}}{6}$ $\Delta P \leftarrow p_t - p_{t-1}$ $\Delta P\% \leftarrow \frac{p_t - p_{t-1}}{p_{t-1}} \times 100$ $\text{Target} \leftarrow p_{t+1}$ End for $\text{Remove}(\text{NaN})$
Phase 3 : Data Transformation $X \leftarrow \{\text{Year, Month, Price,}$ $\text{Lag}_1, \text{Lag}_2, \text{Lag}_3,$ $MA_3, MA_6, \Delta P,$ $\Delta P\%, \text{Commodity}\}$ $y \leftarrow \text{Target}$ $X \leftarrow \text{OneHotEncoding}(X_{\text{commodity}})$ $\{\text{Train}, \text{Test}\} \leftarrow \text{TimeBasedSplit}(X, y)$ $XLR \leftarrow \text{StandardScaler}(\text{Train})$
Phase 4 : Model Development For $\text{Model} \in \{\text{LinearRegression},$ $\text{RandomForest}\}$ do For $\text{Tuning} \in \{\text{GridSearch},$ $\text{RandomSearch},$ $\text{BayesianOptimization}\}$ do $\theta^* \leftarrow \arg \min \text{RMSECV}(\text{model}, \text{tuning})$ $\text{Train}(\text{Model}, \theta^*)$ $\hat{y} \leftarrow \text{Predict}(\text{Test})$ $\text{Evaluate}(\text{MAE}, \text{RMSE}, \text{MAPE}, R^2)$ End for End for
Phase 5 : Model Development $M_{best} \leftarrow \arg \max(R^2)$

$$Return(M_{best})$$

3. PEMBAHASAN DAN HASIL


3.1. Analisis Eksploratif Data (EDA)

Analisis diawali dengan *Exploratory Data Analysis (EDA)* untuk mengidentifikasi distribusi harga, pencilan, dan pola temporal pada data sebelum proses pemodelan. Analisis eksploratif pertama diarahkan pada identifikasi sebaran nilai harga dan deteksi pencilan riil di dalam dataset tingkat konsumen nasional melalui visualisasi *boxplot* yang ditunjukkan pada Gambar 2.



Gambar 2. Sebaran Nilai Harga Komoditas Pangan


Pada Gambar 2 menunjukkan sebagian besar harga pangan berada pada kisaran Rp10.000–Rp40.000/kg dengan distribusi *right-skewed*. Namun, di sisi kanan diagram terlihat deretan titik jingga yang berada jauh di luar batas garis *whisker* atas, yang secara statistik diidentifikasi sebagai pencilan atau *outlier*. Berdasarkan analisis data, pencilan tersebut sengaja dipertahankan di dalam dataset dan tidak dihapus karena nilai tersebut mencerminkan realitas ekonomi asli dari rumpun komoditas peternakan yang memiliki harga dasar tinggi di pasar riil, seperti komoditas Daging Kerbau Segar Lokal dan Daging Sapi Murni yang rata-rata harganya berada di atas Rp100.000 per kilogram. Guna melihat bagaimana karakteristik volatilitas ini bergerak secara kronologis pada tingkat komoditas individual, Gambar 3 menyajikan visualisasi tren komparatif beberapa komoditas pangan utama.



Gambar 3. Grafik Garis Tren Perbandingan Karakteristik Volatilitas Lima Komoditas Pangan Utama

Visualisasi runtun waktu pada Gambar 3 menunjukkan secara kontras perbedaan karakteristik perilaku harga antar-komoditas pangan konsumen yang menjadi alasan utama mengapa model nonlinier diperlukan. Komoditas Bawang Merah menunjukkan

tingkat volatilitas harga yang sangat radikal dengan pola lonjakan dan penurunan yang tajam di sepanjang tahun pengamatan akibat guncangan pasokan musiman. Karakteristik yang bertolak belakang diperlihatkan oleh komoditas Beras Premium dan Beras Medium yang bergerak secara konsisten, stabil, lambat, dan minim guncangan dari waktu ke waktu. Perbedaan pola yang ekstrem antar-komoditas ini memberikan pembuktian ilmiah mengenai keterbatasan fungsi linier satu garis dan memperkuat alasan pemilihan algoritma berbasis *ensemble learning* seperti *Random Forest* yang tangguh dalam menangani multi-karakteristik data. Sebagai kesimpulan fase eksplorasi, interaksi korelasi rata-rata harga keseluruhan komoditas berdasarkan dimensi kronologis waktu divisualisasikan melalui matriks *heatmap* pada Gambar 4.



Gambar 4. Matriks Heatmap Rata-rata Harga Pangan Berdasarkan Dimensi Tahun dan Bulan

Matriks *heatmap* pada Gambar 4 memberikan konfirmasi bahwa rata-rata harga pangan relatif stabil pada periode 2021–2024, kemudian meningkat pada 2025 hingga awal 2026. Pola tersebut mengindikasikan adanya ketergantungan harga terhadap dimensi waktu sehingga mendukung penerapan fitur temporal seperti *lag features* dan *moving average*.

3.2. Pra-pemrosesan Data dan Eksekusi Rekayasa Fitur

Tahap pra-pemrosesan meliputi normalisasi nama kolom, konversi atribut harga ke format numerik, serta penanganan 16 *missing value* menggunakan interpolasi linier yang dikombinasikan dengan *forward fill* dan *backward fill*. Output keberhasilan tahapan pembersihan data ditunjukkan pada Gambar 5 dan Gambar 6.

	Komoditas	Tahun	Bulan	Harga
169	Minyak Goreng Curah	2022	Januari	NaN
170	Jagung Tk. Peternak	2022	Januari	NaN
184	Minyak Goreng Curah	2022	Februari	NaN
185	Jagung Tk. Peternak	2022	Februari	NaN
199	Minyak Goreng Curah	2022	Maret	NaN
200	Jagung Tk. Peternak	2022	Maret	NaN
215	Jagung Tk. Peternak	2022	April	NaN
348	Tepung Terigu Kemasan	2023	Januari	NaN
352	Ikan Kembung	2023	Januari	NaN
353	Ikan Tongkol	2023	Januari	NaN
354	Ikan Bandeng	2023	Januari	NaN
355	Garam konsumsi	2023	Januari	NaN
368	Tepung Terigu Kemasan	2023	Februari	NaN
375	Garam konsumsi	2023	Februari	NaN
388	Tepung Terigu Kemasan	2023	Maret	NaN
395	Garam konsumsi	2023	Maret	NaN

Gambar 5. Pembersihan Kolom Harga Menjadi Format Numerik Kontinu

Missing Harga sebelum imputasi: 16
Missing Harga setelah imputasi: 0

Gambar 6. Keberhasilan Imputasi Missing Value Menjadi Nol

Setelah proses imputasi selesai, dilakukan validasi statistik deskriptif untuk memastikan kualitas data sebelum tahap pemodelan yang di tunjukan pada Gambar 7.

	Komoditas	Jumlah_Data	Harga_Min	Harga_Rata_Rata	Harga_Max	Harga_Std
12	Daging Kerbau Segar (Lokal)	15	140557.0	141881.066667	144686.0	1387.470230
13	Daging Sapi Murni	64	121836.0	133266.328125	141350.0	4774.770045
11	Daging Kerbau Beku (Impor)	15	105220.0	108166.666667	117260.0	3807.435314
9	Cabai Rawit Merah	64	35465.0	58045.406250	92656.0	13662.674476
7	Cabai Merah Besar	15	38269.0	47073.933333	54278.0	4998.236453
8	Cabai Merah Kenting	64	28052.0	46410.609375	76189.0	10095.949145
17	Ikan Kembung	40	38235.0	40836.850000	46233.0	1923.913327
0	Bawang Merah	64	24403.0	36547.656250	57859.0	6918.365408
10	Daging Ayam Ras	64	33457.0	36443.625000	41312.0	1727.411427
16	Ikan Bandeng	40	33523.0	35597.425000	38691.0	1373.396200
18	Ikan Tongkol	40	32244.0	35154.625000	38462.0	1661.089242
1	Bawang Putih (Bonggol)	64	25701.0	34834.703125	44750.0	6051.821323
25	Telur Ayam Ras	64	22611.0	28370.500000	31923.0	2295.623061

Gambar 7. Ringkasan Validasi Statistik Deskriptif Kolom Harga per Komoditas Pasca-Pembersihan

Selanjutnya dibangun delapan fitur temporal yang terdiri atas *Lag-1*, *Lag-2*, *Lag-3*, *Moving Average 3*, *Moving Average 6*, *Price Difference*, *Percentage Change*, dan Target Harga Bulan Berikutnya. Pembentukan fitur menyebabkan munculnya nilai kosong pada awal setiap deret waktu sehingga baris tersebut dihapus untuk menghasilkan dataset akhir yang lengkap yang ditunjukkan pada Gambar 8.

	Komoditas	Tanggal	Harga	Perubahan_Harga	Persentase_Perubahan_Harga
0	Bawang Merah	2021-01-01	30329.0	NaN	NaN
1	Bawang Merah	2021-02-01	29996.0	-333.0	-1.097959
2	Bawang Merah	2021-03-01	33050.0	3054.0	10.181358
3	Bawang Merah	2021-04-01	31729.0	-1321.0	-3.996974
4	Bawang Merah	2021-05-01	31355.0	-374.0	-1.178732
5	Bawang Merah	2021-06-01	29914.0	-1441.0	-4.595758
6	Bawang Merah	2021-07-01	31897.0	1983.0	6.629003
7	Bawang Merah	2021-08-01	32657.0	760.0	2.382669
8	Bawang Merah	2021-09-01	28890.0	-3767.0	-11.535046
9	Bawang Merah	2021-10-01	28004.0	-886.0	-3.066805
10	Bawang Merah	2021-11-01	26510.0	-1494.0	-5.334952
11	Bawang Merah	2021-12-01	26854.0	344.0	1.297624
12	Bawang Merah	2022-01-01	26672.0	1818.0	6.769941
13	Bawang Merah	2022-02-01	31832.0	3160.0	11.021205
14	Bawang Merah	2022-03-01	35044.0	3212.0	10.090475

Gambar 8. Ringkasan Validasi Statistik Deskriptif Kolom Harga per Komoditas Pasca-Pembersihan

Langkah akhir pra-pemrosesan ditutup dengan mengubah atribut kategorikal *Komoditas* menjadi fitur biner bernilai 0 dan 1 memanfaatkan fungsi biner *One-Hot Encoding* menggunakan `get_dummies()`. Dataset runtun waktu yang telah kaya akan fitur temporal ini selanjutnya dipisahkan menggunakan pendekatan *Time-Based Split* kronologis dengan proporsi seimbang 80% untuk data latih dan 20% untuk data uji demi menghindari kebocoran data masa depan (*data leakage*). Pembagian ini menghasilkan volume data latih sebanyak 760 observasi yang mengover rentang waktu dari Juli 2021 hingga Maret 2025, serta volume data uji sebanyak 280 observasi yang mencakup rentang waktu pengujian dari April 2025 hingga Maret 2026. Seluruh fitur numerik eksogenus kemudian distandardisasi skalanya memanfaatkan fungsi `StandardScaler` agar model dapat melakukan pembaruan bobot secara seimbang selama pelatihan model.

3.3. Hasil Model Regresi dan Efektivitas Optimasi Hyperparameter

Setelah seluruh variasi arsitektur model berhasil dilatih menggunakan data latih, setiap model diuji kinerjanya untuk memprediksi nilai target harga bulan berikutnya pada data uji. Hasil pengujian menunjukkan bahwa setiap rumpun model memiliki kemampuan yang berbeda dalam menangkap karakteristik volatilitas harga pangan, di mana ringkasan performa kuantitatif dari hasil prediksi setiap model disajikan secara mendetail pada Tabel 3.


Tabel 3. *performance models and tuning strategies*

Model	Hyperparameter Tuning	MAE	RMSE	MAPE	R ²
Linear Regression	Grid Search	4634.90	12120.24	9.39	0.8775
Linear Regression	Random Search	4634.90	12120.24	9.39	0.8775
Linear Regression	Bayesian Optimization	4634.90	12120.24	9.39	0.8775
Random Forest Regression	Grid Search	2028.19	4566.37	3.67	0.9826
Random Forest Regression	Random Search	2135.08	4890.55	3.78	0.9800
Random Forest Regression	Bayesian Optimization	2028.19	4566.37	3.67	0.9826

Berdasarkan Tabel 3, *Random Forest Regression* memberikan performa yang lebih baik dibandingkan *Linear Regression* pada seluruh metrik evaluasi. *Linear Regression* menghasilkan MAE 4.634,90, RMSE 12.120,24, MAPE 9,39%, dan R^2 0,8775. Hasil yang identik pada seluruh metode optimasi menunjukkan bahwa optimasi hyperparameter tidak memberikan pengaruh terhadap model ini karena tidak memiliki struktur parameter yang kompleks.

Sebaliknya, *Random Forest Regression* menunjukkan performa terbaik. Optimasi menggunakan *Grid Search* dan *Bayesian Optimization* menghasilkan nilai MAE 2.028,19, RMSE 4.566,37, MAPE 3,67%, dan R^2 0,9826, sedangkan *Random Search* memperoleh hasil yang sedikit lebih rendah (R^2 0,9800 dan MAPE 3,78%). Temuan ini menunjukkan bahwa *Grid Search* dan *Bayesian Optimization* lebih efektif dalam menemukan kombinasi *hyperparameter* optimal.

Secara keseluruhan, hasil evaluasi menunjukkan bahwa algoritma *Random Forest Regression* lebih mampu mempelajari hubungan yang kompleks dan pola historis perubahan harga komoditas pangan dibandingkan *Linear Regression*. Hal ini disebabkan karena *Random Forest* bekerja sebagai model ensemble yang melatih banyak pohon keputusan secara independen, sehingga dapat menangani hubungan nonlinier antar-fitur temporal secara simultan serta mengurangi risiko *overfitting* dan sensitivitas terhadap pencilaan. Visualisasi grafis yang membandingkan keselarasan plot kurva antara deret nilai aktual harga pangan nasional dengan nilai hasil prediksi dari arsitektur model regresi terbaik ini disajikan pada Gambar 8.



Gambar 8. Grafik Komparasi Deret Plot Nilai Aktual dengan Hasil Prediksi Model Terbaik

Plot kurva pada Gambar 8 memperlihatkan tingkat kedekatan yang sangat presisi antara garis biru penanda nilai harga aktual dengan garis jingga penanda nilai hasil prediksi model di sepanjang sumbu kronologis data uji dari April 2025 hingga Maret 2026. Keberhasilan model dalam mengikuti lekukan fluktuasi harga yang tajam tanpa mengalami penundaan (*lagging*) membuktikan kekuatan fitur hasil rekayasa temporal dalam mereduksi *noise* fluktuasi acak secara optimal, sehingga model terpilih ini secara sah ditetapkan sebagai arsitektur prediksi terbaik dalam penelitian ini.

4. KESIMPULAN

Penelitian ini berhasil mengembangkan model prediksi harga komoditas pangan bulanan tingkat konsumen nasional menggunakan *Linear Regression* dan *Random Forest Regression*. Prosesnya meliputi pengumpulan *data*, *preprocessing*, *feature engineering*, pembagian *dataset* menggunakan *time-based split*, serta evaluasi model berdasarkan metrik MAE, RMSE, MAPE, dan R^2 . Hasil penelitian menunjukkan bahwa penerapan *feature engineering temporal* yang terdiri atas *Lag-1*, *Lag-2*, *Lag-3*, *Moving Average 3*, *Moving Average 6*, *Price Difference*, dan *Percentage Change* mampu meningkatkan representasi pola historis sehingga mendukung peningkatan akurasi prediksi.

Hasil evaluasi menunjukkan bahwa *Random Forest Regression* memberikan performa yang lebih baik dibandingkan *Linear Regression* pada seluruh metrik evaluasi. Optimasi *Grid Search* dan *Bayesian Optimization* menghasilkan performa terbaik dengan nilai MAE sebesar 2.028,19, RMSE sebesar 4.566,37, MAPE sebesar 3,67%, dan R^2 sebesar 0,9826, sedangkan *Random Search* menghasilkan performa yang sedikit lebih rendah namun tetap kompetitif. Hasil tersebut menunjukkan bahwa kombinasi *feature engineering temporal* dan optimasi *hyperparameter* mampu meningkatkan kemampuan model dalam memprediksi harga komoditas pangan bulanan.

Berdasarkan hasil tersebut, *Random Forest Regression* dengan optimasi *Grid Search* atau *Bayesian Optimization* menjadi model terbaik untuk memprediksi harga komoditas pangan nasional karena mampu menjelaskan 98,26% variasi data pada periode pengujian. Model ini berpotensi dimanfaatkan sebagai pendukung pengambilan keputusan dalam pengendalian inflasi, pengelolaan distribusi pangan, serta perencanaan kebutuhan komoditas.

Penelitian selanjutnya dapat mengembangkan model dengan menambahkan variabel eksternal, seperti tingkat inflasi, kondisi cuaca, volume produksi pertanian, dan kebijakan pemerintah. Selain itu, penelitian dapat dibandingkan dengan algoritma lain, seperti *XGBoost*, *LightGBM*, dan *Long Short-Term Memory (LSTM)*, serta mengimplementasikan model ke dalam sistem pendukung keputusan berbasis *web* atau *mobile* untuk mendukung pemantauan harga pangan secara berkelanjutan.

DAFTAR PUSTAKA

- Bahtiar, R., & Raswatie, F. D. (2023). Analisis Fluktuasi Harga Pangan di Kota Bogor. *Indonesian Journal of Agriculture Resource and Environmental Economics*, 1(2), 70–81. <https://doi.org/10.29244/ijaree.v1i2.42020>

- Chen, W., Hussain, W., Cauteruccio, F., & Zhang, X. (2023). Deep Learning for Financial Time Series Prediction: A State-of-the-Art Review of Standalone and Hybrid Models. In *CMES - Computer Modeling in Engineering and Sciences* (Vol. 139, Number 1, pp. 187–224). Tech Science Press. <https://doi.org/10.32604/cmcs.2023.031388>
- Fadillah, R., Ula, M., & Suwanda, R. (2025). Machine Learning to Predict Food Prices in Aceh Province Using the Fuzzy Time Series Method Based on Average. *Sinkron : Jurnal Dan Penelitian Teknik Informatika*, 9(2), 755–761. <https://doi.org/10.33395/sinkron.v9i2.14649>
- Guo, Y., Tang, D., Tang, W., Yang, S., Tang, Q., Feng, Y., & Zhang, F. (2022). Agricultural Price Prediction Based on Combined Forecasting Model under Spatial-Temporal Influencing Factors. *Sustainability (Switzerland)*, 14(17). <https://doi.org/10.3390/su141710483>
- Hertini, E. S., Risdwiyanto, A., Agustina, W., Munizu, M., & Malik, M. A. (2026). PERAN MANAJEMEN LOGISTIK PANGAN TERHADAP STABILITAS HARGA BAHAN POKOK DI INDONESIA. *JURNAL LENTERA BISNIS*, 15(1), 2269–2277. <https://doi.org/10.34127/jrlab.v15i1.2184>
- Hodson, T. O. (2022). Root-mean-square error (RMSE) or mean absolute error (MAE): when to use them or not. In *Geoscientific Model Development* (Vol. 15, Number 14, pp. 5481–5487). Copernicus GmbH. <https://doi.org/10.5194/gmd-15-5481-2022>
- Iliadis, D., Wever, M., De Baets, B., & Waegeman, W. (2024). Hyperparameter optimization of two-branch neural networks in multi-target prediction. *Applied Soft Computing*, 165, 111957. <https://doi.org/https://doi.org/10.1016/j.asoc.2024.111957>
- Javed, A. (2026). Benchmarking econometric, decomposable additive, and neural network methods for food inflation prediction featuring policy insights. *Scientific Reports*, 16(1), 5460. <https://doi.org/10.1038/s41598-026-34993-w>
- Joseph, V. R. (2022). Optimal ratio for data splitting. *Statistical Analysis and Data Mining*, 15(4), 531–538. <https://doi.org/10.1002/sam.11583>
- Khoshvaght, H., Permala, R. R., Razmjou, A., & Khiadani, M. (2025). A critical review on selecting performance evaluation metrics for supervised machine learning models in wastewater quality prediction. In *Journal of Environmental Chemical Engineering* (Vol. 13, Number 6). Elsevier Ltd. <https://doi.org/10.1016/j.jece.2025.119675>
- Lestari, D. R., Bangun, E. A. S., Gaol, F. L., & Matsuo, T. (2025). Machine Learning-Based Forecasting of Agricultural Commodity Prices Using Ensemble Models. *Journal of Human, Earth, and Future*, 6(4), 887–899. <https://doi.org/10.28991/HEF-2025-06-04-09>
- Meisenbacher, S., Turowski, M., Phipps, K., Rätz, M., Müller, D., Hagenmeyer, V., & Mikut, R. (2022). Review of automated time series forecasting pipelines. In *Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery* (Vol. 12, Number 6). John Wiley and Sons Inc. <https://doi.org/10.1002/widm.1475>
- Murtani, M., Kobi, D., & Imelda, I. (2026). Multi-Commodity Food Price Forecasting Ahead of Eid Al-Fitr in Indonesia (2026–2030): A Comparative Study of Machine Learning Algorithms Using Time-Series Data. *MALCOM: Indonesian Journal of Machine Learning and Computer Science*, 6(1), 404–413.
- Ogol, B. O., Omondi, E., Olukuru, J., Muriithi, B., & Senagi, K. (2025). Predicting food prices in Kenya using machine learning: a hybrid model approach with XGBoost and gradient boosting. *Frontiers in Artificial Intelligence*, Volume 8-2025. <https://doi.org/10.3389/frai.2025.1661989>
- Pandit, P., Sagar, A., Ghose, B., Dey, P., Paul, M., Alqadhi, S., Mallick, J., Almohamad, H., & Abdo, H. G. (2023). Hybrid time series models with exogenous variable for improved yield forecasting of major Rabi crops in India. *Scientific Reports*, 13(1). <https://doi.org/10.1038/s41598-023-49544-w>
- Rasyid Muchtar, I. (2024). Comparison of Linear Regression and Random Forest Algorithms for Premium Rice Price Prediction (Case Study: West Java). *Jurnal Indonesia Sosial Teknologi*, 5(7), 3122. <http://jst.publikasiindonesia.id/>
- Sari, L., Achsani, N., Sartono, B., & Anggraeni, L. (2023). Investigating The Asymmetric Effect of Food Commodity Price on The Volatility in Indonesia. *Jurnal Manajemen Dan Agribisnis*, 20. <https://doi.org/10.17358/jma.20.3.440>
- Sediyono, E., Hartomo, K. D., Arthur, C., Utami, I., Prabowo, R., & Chiong, R. (2025). An integrated framework for multi-commodity agricultural price forecasting and anomaly detection using attention-boosted models. *Journal of Agriculture and Food Research*, 22. <https://doi.org/10.1016/j.jafr.2025.102021>
- Sifriyani, S., Rasjid, M., Rosadi, D., Anwar, S., Wahyuni, R. D., & Jalaluddin, S. (2022). Spatial-Temporal Epidemiology of COVID-19 Using a Geographically and Temporally Weighted Regression Model. *Symmetry*, 14(4). <https://doi.org/10.3390/sym14040742>
- Suaza-Medina, M. E., Zarazaga-Soria, F. J., Pinilla-Lopez, J., Lopez-Pellicer, F. J., & Lacasta, J. (2023). Effects of data time lag in a decision-

- making system using machine learning for pork price prediction. *Neural Computing and Applications*, 35(26), 19221–19233. <https://doi.org/10.1007/s00521-023-08730-7>
- Sun, M., Gong, A., Zhao, X., Liu, N., Si, L., & Zhao, S. (2023). Reconstruction of a Monthly 1 km NDVI Time Series Product in China Using Random Forest Methodology. *Remote Sensing*, 15(13). <https://doi.org/10.3390/rs15133353>
- Ulussever, T., Ertuğrul, H. M., Kılıç Depren, S., Kartal, M. T., & Depren, Ö. (2023). Estimation of Impacts of Global Factors on World Food Prices: A Comparison of Machine Learning Algorithms and Time Series Econometric Models. *Foods*, 12(4). <https://doi.org/10.3390/foods12040873>
- Wang, Y.-A., Huang, Q., Yao, Z., & Zhang, Y. (2024). On a class of linear regression methods. *Journal of Complexity*, 82, 101826. <https://doi.org/https://doi.org/10.1016/j.jco.2024.101826>
- Yan, H., Manfredo, M., & Mishra, A. K. (2026). Forecasting for food price inflation using machine learning methodology: Expansion on FRED-MD. *Food Policy*, 140, 103077. <https://doi.org/https://doi.org/10.1016/j.foodpo.2026.103077>
- Zhou, Z., Qiu, C., & Zhang, Y. (2023). A comparative analysis of linear regression, neural networks and random forest regression for predicting air ozone employing soft sensor models. *Scientific Reports*, 13(1). <https://doi.org/10.1038/s41598-023-49899-0>